

Métodos de Estatística Aplicada com Python

Aula 1

Carlos Góes¹

¹Pós-Graduação em Ciência de Dados
Instituto de Educação Superior de Brasília

2017

Sumário

- 1 Introdução ao curso
 - Professor
 - O que é ciência de dados? E por que estatística importa?
 - Estrutura do curso
- 2 Introdução à estatística
 - O que é estatística?
 - Definições
 - Problemas na análise estatística
- 3 Introdução ao Python
 - Por que Python?
 - Introdução ao Spyder
 - Integers, floats, strings e booleans
 - Listas e dicionários

Sumário

- 1 Introdução ao curso
 - Professor
 - O que é ciência de dados? E por que estatística importa?
 - Estrutura do curso
- 2 Introdução à estatística
 - O que é estatística?
 - Definições
 - Problemas na análise estatística
- 3 Introdução ao Python
 - Por que Python?
 - Introdução ao Spyder
 - Integers, floats, strings e booleans
 - Listas e dicionários

Professor

Por que eu estou dando aula para vocês?

- Educacional

- PhD em Economia (em andamento), UCSD
- Mestre em Economia Internacional (2013), Johns Hopkins
- Bacharel em Relações Internacionais (2011), UnB

- Profissional

- Assessor Especial para Desenvolvimento Econômico, Secretaria Especial de Assuntos Estratégicos (2017-)
- Pesquisador-Chefe, Instituto Mercado Popular (2016-)
- Analista Econômico, FMI (2013-17)
- Pesquisador, Instituto Cato (2012)

O que é ciência de dados?

O que faz você diferente de um estatístico ou um cientista da computação?




Figura: Diagrama de Conway. Componentes que compõem a ciência de dados e suas intersecções

Estrutura do curso

O que vamos fazer aprender aqui?

- O objetivo do curso é prover instrumentos teóricos e práticos necessários à compreensão de:
 - tipos distintos de variáveis;
 - apresentação de dados em tabelas e gráficos;
 - medidas descritivas (média, mediana, moda, quantis);
 - medidas de variação (desvio padrão, variância);
 - população vs. amostras;
 - distribuições, erro padrão e significância estatística;
 - introdução à programação estatística;
 - automatização da busca, organização e tratamento de dados empíricos;
e
 - utilização tais dados para extrair estatísticas descritivas, fatos estilizados e análises gráficas.

Estrutura do curso

Como vamos aprender isso?

curso = teoria + pratica

- Teoria: teoria estatística, conceitos, compreensão acadêmica.
- Prática: programação aplicada à estatística.

Sumário

- 1 Introdução ao curso
 - Professor
 - O que é ciência de dados? E por que estatística importa?
 - Estrutura do curso
- 2 Introdução à estatística
 - O que é estatística?
 - Definições
 - Problemas na análise estatística
- 3 Introdução ao Python
 - Por que Python?
 - Introdução ao Spyder
 - Integers, floats, strings e booleans
 - Listas e dicionários

O que é estatística?

Como ela nos ajuda a compreender o mundo

- Estatística é um *conjunto de métodos* para planejar experimentos e obter dados e derivar conclusões de tal dados depois de:
 - organizá-los;
 - resumi-los;
 - analisá-los; e
 - interpretá-los.

Definições

Dados

- Dados são coleções de observações específicas sobre indivíduos, domicílio, países, máquinas, fábricas, etc.
- Exemplo. *A Pesquisa Nacional de Amostra de Domicílios*, realizada pelo IBGE anualmente, coleta uma série de informações sobre características de domicílios brasileiros:
 - Domicílio 1: {*UF: DF; Município: Brasília; Número de habitantes: 3; Número de cômodos: 2; Tem geladeira: Sim; Tem TV a Cores: Sim; Tem máquina de lavar: Sim; Renda familiar habitual no mês: R\$ 18.000,00; etc.*};
 - Domicílio 2: {*UF: MA; Município: São Luís; Número de habitantes: 5; Número de cômodos: 2; Tem geladeira: Sim; Tem TV a Cores: Sim; Tem máquina de lavar: Não; Renda familiar habitual no mês: R\$ 2.000,00; etc.*};
 - etc...

Definições

População, amostra e censo

- População: conjunto completo de indivíduos, objetos ou unidades sobre os quais queremos informações.
- Amostra: subconjunto de unidades da *população* acerca das quais realmente coletamos informações.
 - Importante: Um dos objetivos da ciência estatística é desenhar pesquisas estatísticas de modo a que as *amostras sejam representativas* - isto é, que as informações inferidas sobre a *amostra* representem as características da *população*.
- Censo: tentativa de amostrar toda a população.
 - Além do Censo Demográfico (que ocorre a cada 10 anos), há algum outro Censo no Brasil?

Definições

Variáveis, parâmetros e estatísticas

- Variáveis: características que medimos em cada unidade.
 - Exemplos: Salário; idade; e sexo de indivíduos. Cada uma dessas é uma *variável*.
- Parâmetros: características numéricas da população.
 - normalmente, são essas características que queremos saber, mas é muito difícil e custoso medir as características de toda a população ao longo de muitos períodos.
- Estatísticas: características numéricas da *amostra*.
 - Estatísticas (da amostra) são utilizadas para estimar os parâmetros (da população)

Definições

Tipos de variáveis




Figura: Tipos de variáveis. Detalhamento

Definições

Tipos de variáveis: quantitativas

- Variáveis quantitativas são aquelas que se referem a medições e contagens.
 - Variáveis discretas: são aquelas em que a contagem segue um intervalo pré-determinado. *Exemplo: quantos anos de estudo você completou?*
 - Variáveis contínuas: são aquelas em que a contagem inclui frações infinitesimais. *Exemplo: qual seu peso/altura?*

Definições

Tipos de variáveis: qualitativas

- Variáveis qualitativas são aquelas que definem grupos que classificam os indivíduos da amostra.
 - Variáveis categóricas: são aquelas em que não há ideia de ordem entre as variáveis. *Exemplo: grupo sanguíneo; religião.*
 - Variáveis ordinais: são aquelas em que a contagem inclui frações infinitesimais. *Exemplo: classe - baixa/média/alta; escolaridade - fundamental/médio/superior.*

Problemas na análise estatística

Representatividade

- Para ser úteis, estatísticas têm de ser representativas.
 - Exemplo: se você pesquisar o que as pessoas acham do Lula (FHC) na frente do Congresso Nacional do PT (PSDB), o resultado da pesquisa não será representativo do conjunto da população.

Problemas na análise estatística

Vieses

- Viés de auto-seleção:
 - a REVISTA ÉPOCA faz uma enquete sobre *cobrança de imposto de igrejas* em seu *site*. O resultado é que 95% dos votantes é contrário. Logo depois, descobre-se que líderes religiosos pediram para fiéis votarem na enquete. Ela representa o conjunto da população brasileira?

Problemas na análise estatística

Vieses

- Viés de seleção:
 - fazem uma pesquisa que escolhe *aleatoriamente* (ou seja, sem viés de auto-seleção) pessoas para responder a seguinte pergunta: "A mudança climática é causada por fatores humanos?". 99% dos respondentes disseram que sim. Mas a pesquisa só inclui pesquisadores da NASA. Ela representa o conjunto da população americana?

Problemas na análise estatística

Vieses

- Viés causado pela formulação de pergunta perguntas:
 - Você concorda com a reforma trabalhista?
 - Você concorda com a *retirada de direitos promovida pela reforma trabalhista*?
 - Você concorda com a reforma trabalhista, *considerando que ela vai aumentar a probabilidade de trabalhadores pobres encontrarem um emprego formal*?

Problemas na análise estatística

A pesquisa estatística bem planejada

- Definir circunscrições de interesse
- Escolher unidades/indivíduos aleatoriamente dentro de cada área de interesse
- Definir pesos representativos com base em características demográficas conhecidas (região, religião, sexo, raça, etc...).

Problemas na análise estatística

A pesquisa estatística bem planejada




Figura: IBGE. Metodologia de estratificação da PNAD.

Problemas na análise estatística

O experimento estatístico ideal

- Escolher aleatoriamente unidades para teste
- Escolher aleatoriamente grupo de tratamento e grupo de controle
- Tratar um dos grupos e observar

Problemas na análise estatística

O experimento estatístico ideal




Figura: Experimento. Exemplo conceitual de experimento com grupos de tratamento e controle aleatorizados.

Problemas na análise estatística

E se não podemos fazer um experimento estatístico ideal?

- Nem sempre isso é possível
- Por isso, muitas vezes temos que fazer estudos “observacionais”
- E sempre lembrar que correlação não é causalidade

Problemas na análise estatística

Correlação não é causalidade




Figura: Correlação Espúria. Exemplo de como correlação nem sempre é indício causalidade.

Problemas na análise estatística

E se não podemos fazer um experimento estatístico ideal?

- Uma alternativa é buscar métodos “experimentos naturais”.
- Exemplos:
 - Refugiados com características similares são alocados aleatoriamente em cidades diferentes
 - Em uma cidade que está na divisa de dois estados diferentes, a lei de um dos estados aumenta o salário mínimo em parte da cidade mas não no outro
 - Por causa de um “acidente histórico”, um país se torna metade capitalista e metade socialista

Problemas na análise estatística

Experimentos naturais




Figura: Experimentos Naturais. A divisão da Coreia em dois países e sua diferente performance econômica é, muitas vezes, tido como um experimento natural de modelos econômicos.

Sumário

- 1 Introdução ao curso
 - Professor
 - O que é ciência de dados? E por que estatística importa?
 - Estrutura do curso
- 2 Introdução à estatística
 - O que é estatística?
 - Definições
 - Problemas na análise estatística
- 3 Introdução ao Python
 - Por que Python?
 - Introdução ao Spyder
 - Integers, floats, strings e booleans
 - Listas e dicionários

Por que Python?

Python para ciência de dados

- Python é uma linguagem de programação geral que tem crescente popularidade tanto em ciência de dados quanto para outros propósitos.
- Python prioria a interpretação do código por seres humanos - e é muito fácil para quem está aprendendo.
- Segue princípios como (ver *Zen of Python*):
 - O explícito é melhor do que o implícito;
 - O simples é melhor do que o complexo;
 - Facilidade de leitura importa.

Por que o Python?

Fácil compreensão

Java

```
class myprog
{
    public static void main(String args[])
    {
        System.out.println("Oi!");
    }
}
```

Python

```
print("Oi!")
```

Por que o Python?

R vs. Python



Figura: R vs. Python. Qual é a melhor linguagem?

Por que o Python?

Comparação entre linguagens




Figura: Linguagens de ciência de dados. Tendências de popularidade

Introdução ao Spyder

O que é o Spyder?

- Spyder (*Scientific PYthon Development EnviRonment*) é um ambiente de desenvolvimento interativo que facilita a programação de programas específicos para ciência de dados.
- Como ele facilita a nossa vida?
 - Avisa quando seu código está errado;
 - Facilita a compreensão de seu código por meio de coloração;
 - Mostra o seu código (editor) e o resultado (console de comando) dele na mesma janela;
 - Exibe quais objetos estão gravadas na memória, após a você rodar seu código parcialmente;
 - Tem ferramentas fáceis para acessar a ajuda/documentação, quando você não sabe direito o que fazer.

Introdução ao Spyder

Como usar o Spyder?

The image shows the Spyder Python IDE interface with three main components highlighted by yellow boxes:

- Editor:** The left pane shows a Python script with the following code:


```

1 # coding: utf-8
2
3
4
5
6
7
8 import pandas as pd
9 import numpy as np
10
11 ## Series and DataFrames
12
13 # Create a dictionary (it works with lists, too)
14
15 idnumber = {
16     "Carlos Goes": "06/99209",
17     "Nicolos Powdayho": "10/22290",
18     "Alexander Rabbit": "08/22340",
19     "Dani Alaine": "07/20340",
20     "Lya Nikote": "09/23567",
21     "Nick Borroz": "11/22035"
22 }
23
24 # Transform it into a Pandas Series
25
26 idnumber = pd.Series(idnumber)
27
28 # You can use iloc and loc to return the values for each numerical o
29
30 print(idnumber.loc["Carlos Goes"])
31 print(idnumber.iloc[1])
32
33 # You can also create the pandas series directly
34
35 idnumber = pd.Series({

```
- Explorador de variáveis:** The top right pane displays a table of variables:

Nome	Tipo	Tamanho	Valor
df	DataFrame	(6, 3)	Column names: idnumber, maior, gpa
extracurricular	DataFrame	(5, 3)	Column names: Dean's List, Model UN, Teaching Assistant
EP			
ldr	DataFrame	(3, 6)	Exochord, Assistant, List, Model UN,
linter	DataFrame	(3, 6)	Exochord, Assistant,
- Console de comando:** The bottom right pane shows a scatter plot with a regression line and the following command history:


```

In [3]: 2+2
Out[3]: 4

In [4]:

```

Figura: Spyder. Componentes do IDE.

Integers, floats, strings e booleans

Integers

- Integers são números *inteiros* (sem decimais ou frações).

$$\mathbb{Z} \equiv \{\dots, -3, -2, -1, 0, 1, 2, 3, \dots\} \quad (1)$$

- Exemplo no Python:

```
var = 20
print(type(var))
```

Integers, floats, strings e booleans

Floats

- Floats são representações aritméticas de todos os números *reais*

$$\mathbb{R} \equiv \left\{ \dots, -\pi, -2.5, -\sqrt{2}, -\frac{1}{2}, 0, \frac{1}{2}, \sqrt{2}, 2.5, \pi, \dots \right\} \quad (2)$$

$$\mathbb{R} \equiv \left\{ \dots, -3.14159265, -2.5, -1.41421356, \right. \\ \left. -0.5, 0, 0.5, 1.41421356, 2.5, 3.14159265, \dots \right\}$$

- Exemplo no Python:

```
var = 3.14159265
print(type(var))
```

Integers, floats, strings e booleans

Strings

- Strings são representações de texto.
- Exemplo no Python:

```
var = "Esse é um string"  
print(type(var))
```

Integers, floats, strings e booleans

Booleans

- Booleans são representações lógicas (verdadeiro ou falso).
- Exemplo no Python:

```
var1 = True
print(type(var1))
var2 = (2+2 == 5)
print(type(var2))
```

Integers, floats, strings e booleans

Tipos de variáveis e categorizações teóricas

- Variáveis quantitativas discretas: `integers`.
- Variáveis quantitativas contínuas: `floats`.
- Variáveis qualitativas categóricas: `booleans` ou `strings`.
- Variáveis qualitativas ordinais: `strings` ou `integers`.

Integers, floats, strings e booleans

Operações numéricas

- Adição:

$$x + y$$

- Subtração:

$$x - y$$

- Divisão:

$$x / y$$

- Multiplicação:

$$x * y$$

- Exponenciação:

$$x ** y$$

- Resto:

$$x \% y$$
$$3 \% 2 \text{ is } 1$$

Integers, floats, strings e booleans

Operações com palavras

- Adição:

```
str1 = "Carlos"  
str2 = "Góes"  
print(str1 + " " + str2)
```

- Multiplicação:

```
str1 = "a"  
print(str1 * 10)
```

Integers, floats, strings e booleans

Operações lógicas

- Igualdade:

```
2 + 2 is 4
2 + 2 == 4
str = "a"
str is "a"
str == "a"
```

- Desigualdade:

```
2 + 2 is not 4
2 + 2 != 4
str = "a"
str is not "a"
str != "a"
```

- Maior ou menor que:

```
10 > 100
10 < 100
```

Integers, floats, strings e booleans

Operações lógicas

- Em operações lógicas, True tem o valor de 1 e False tem o valor de 0. Assim, é possível utilizar esse conceito para realizar operações matemáticas.
- Soma (quantos são verdadeiros?):

```
a = 1 + 1 is 2
b = 2 * 2 is 4
c = 2 * 2 is 5
d = a + b + c
print(d)
```

- Multiplicação (todos são verdadeiros?):

```
a = 1 + 1 is 2
b = 2 * 2 is 4
c = 2 * 2 is 5
d = a * b * c
print(d)
```

Listas e dicionários

Listas

- Lists são conjuntos de variáveis ordenadas. Elas podem conter integers, floats, strings ou booleans. Listas são definidas sempre entre [colchetes] e seus elementos são separados por virgulas:

```
lista1 = [2, 20.5, "Oi!", 10 < 100]
print(lista1)
```

- Lists são indexadas de 0 ao elemento $n - 1$ da lista, sendo que n é o número de elementos. Você pode acessar um elemento com a sintaxe `nome_da_lista[indexador]`:
- Por exemplo, `print(lista1[0])` retorna 2.
- Equanto, `print(lista1[3])` retorna True.

Listas e dicionários

Listas

- Você pode alterar um elemento de uma lista atribuindo um valor a um indexador específico:

```
lista1[0]= 20  
print(lista1)
```

- Adicionar um elemento à lista:

```
lista1.append(79.2)  
print(lista1)
```

- Usar multiplicação para repetir o conteúdo da lista:

```
lista2 = lista1 * 2  
print(lista2)
```

- Ou usar adição para juntar duas listas:

```
lista3 = [1,2]  
lista4 = [5,6]  
lista5 = lista3 + lista4
```

Listas e dicionários

Dicionários

- Dictionaries são, como lists, conjuntos de variáveis. Mas, de forma distinta, as informações dentro de dicionários não são indexadas por chaves (normalmente palavras):

```
    pessoa1 = {  
        'nome': 'Milton Friedman',  
        'nascimento': '31/07/1912'  
    }  
    print(pessoa1)  
    print(pessoa1['nome'])
```

- Adicionar um elemento ao dicionário:

```
    pessoa1.update({'nacionalidade': 'EUA'})  
    print(pessoa1)
```