Métodos de Estatística Aplicada com Python

Aula 3

Carlos Góes[1]

[1]Pós-Graduação em Ciência de Dados
Instituto de Educação Superior de Brasília

2017

Sumário

Sumário

Introdução à visualização de dados

Qual é o propósito?

- *"[O]* PRINCIPAL PROPÓSITO *da visualização de dados é comunicar a informação de forma* CLARA *e* EFICIENTE *por meio gráfico . . .*
- *"para transmitir ideias de forma eficiente,* TANTO FUNCIONALIDADE QUANTO ESTÉTICA IMPORTAM, *porque é preciso organizar* DADOS COMPLEXOS *e comunicar seus aspectos principais de uma* FORMA INTUITIVA"
- Vitaly Friedman (2008). "Data Visualization and Infographics" Smashing Magazine.

Introdução à visualização de dados

O que não fazer?

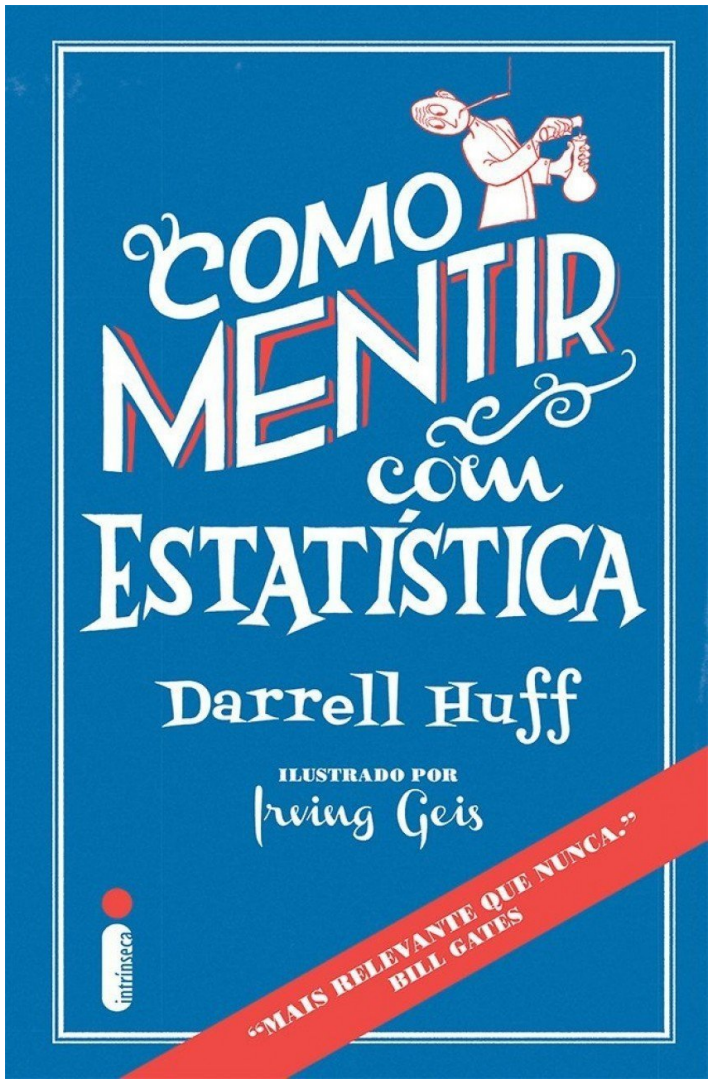

Introdução à visualização de dados

Ex: crescimento da receita de 10%

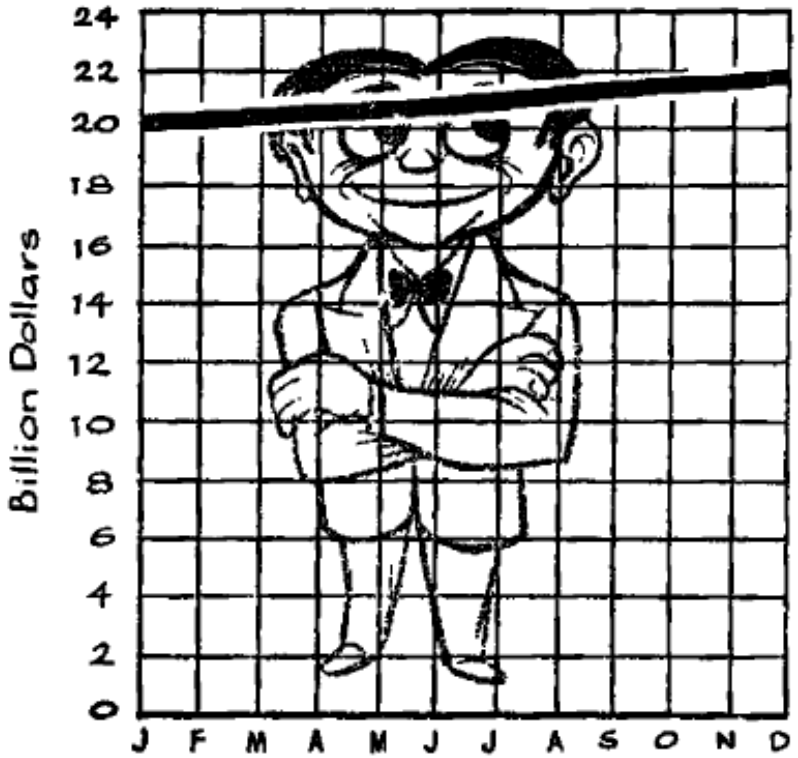

Introdução à visualização de dados

Ex: crescimento da receita de 10%!

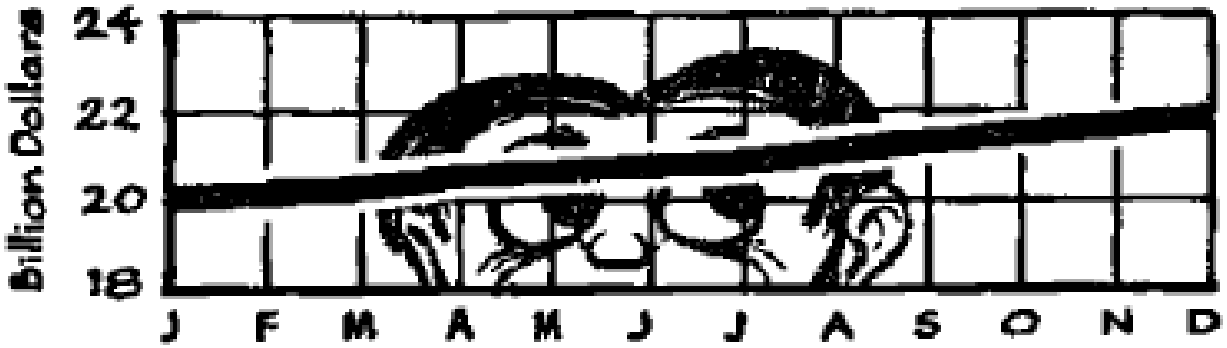

Introdução à visualização de dados

Ex: crescimento da receita de 10%!!!

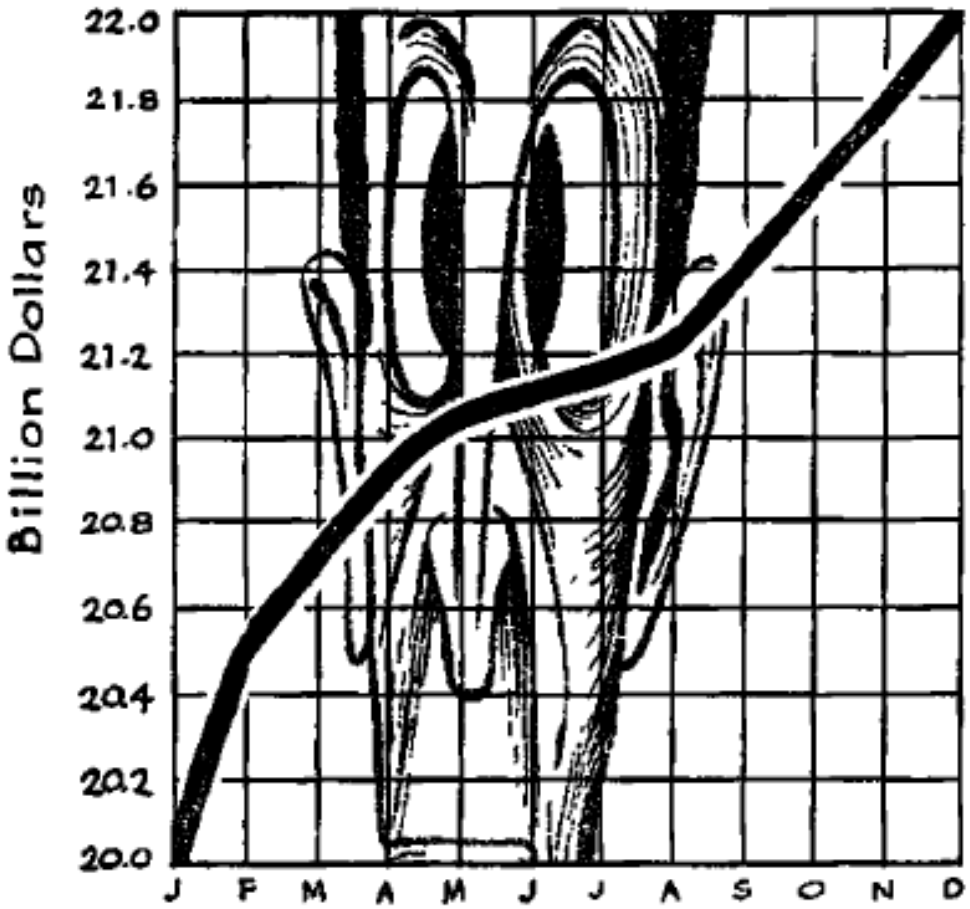

Introdução à visualização de dados

Ex: gastos de pessoal do governo - crescendo ou estáveis?

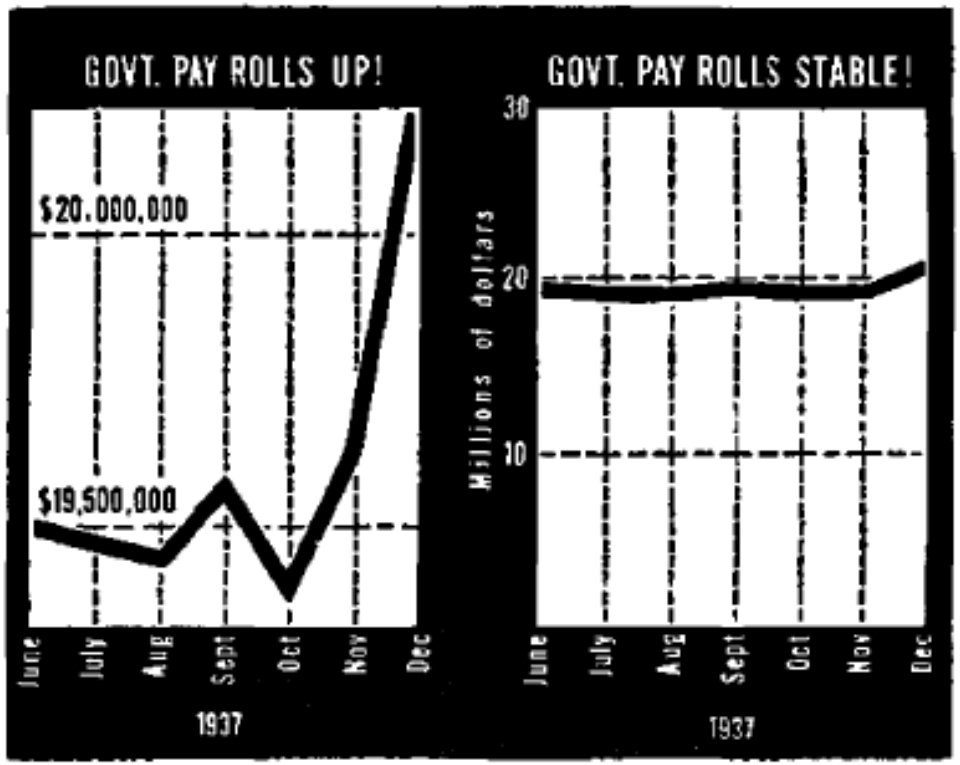

Introdução à visualização de dados

Ex: Resultado das Eleições na Venezuela

Introdução à visualização de dados

Ex: Resultado das Eleições na Venezuela

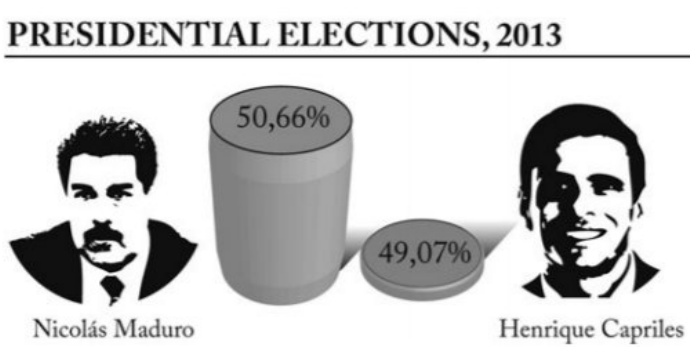

Fig. 5.3 Presidential election results in Venezuela, based on a graphic by Venezonala de Televisión. Notice the truncated *Y*-axis which greatly distorts the difference between the percentages of vote

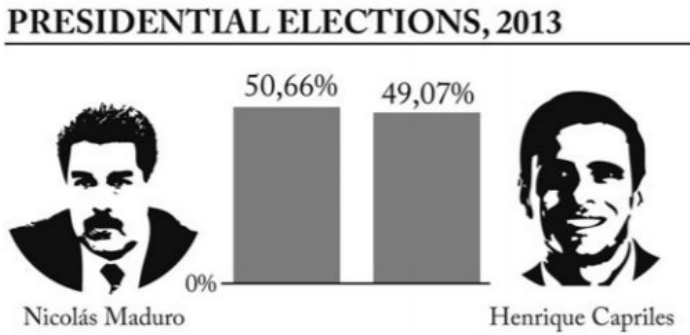

Fig. 5.4 An alternative version of the previous graphic in which a 0-baseline has been added, and the 3D effect has been removed

Introdução à visualização de dados

Mentira vs. erros

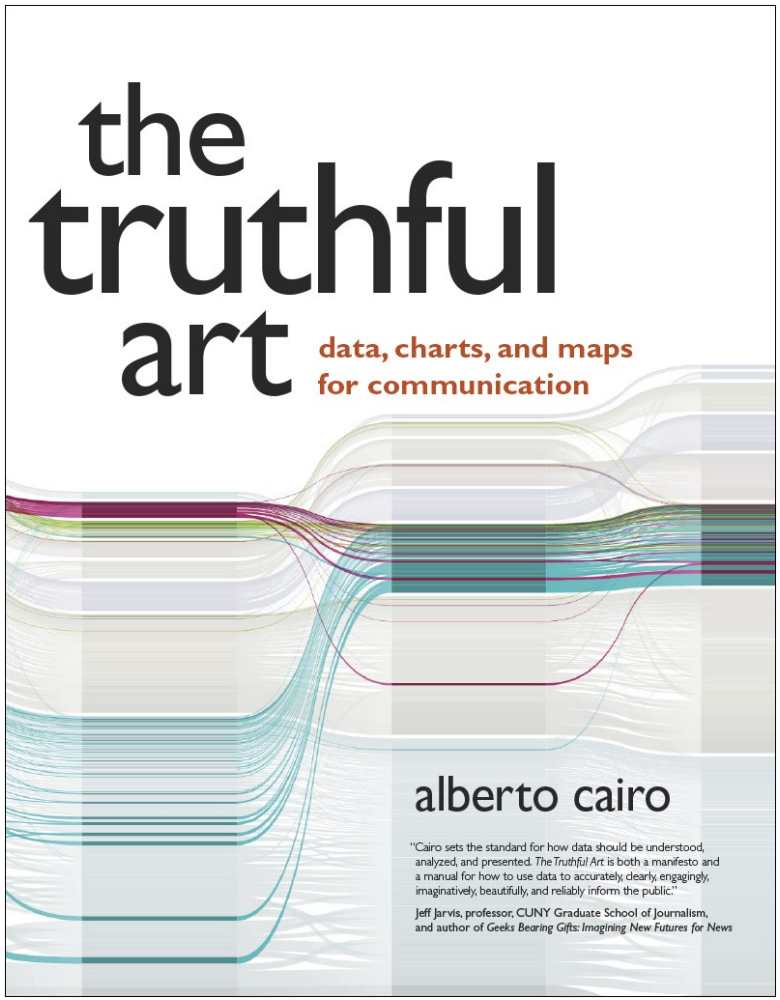

- Mentira é uma violação ética
  - Gráficos não mentem, são pessoas que mentem
- Nem todo erro, contudo, é uma violação ética.
  - Um gráfico pode distorcer a realidade por causa de erros de boa fé. Isso é éticamente neutro.

Introdução à visualização de dados

Mentira vs. erros

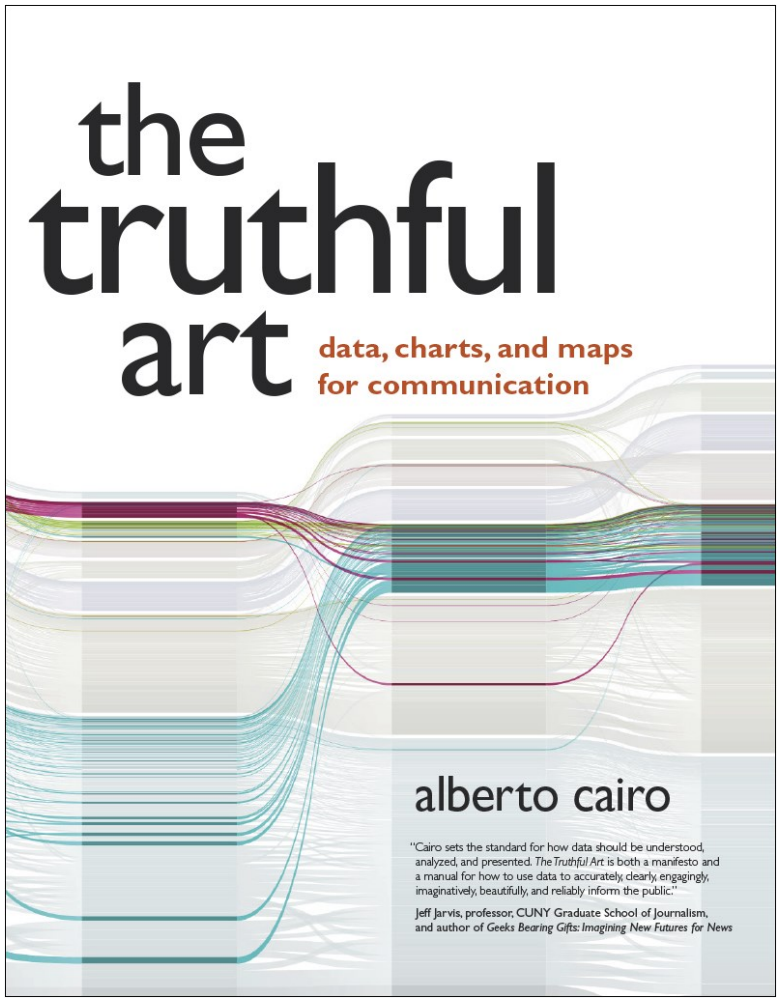

- Três formas de mentir com gráficos:
  1. Esconder dados relevantes para mostrar o que nos beneficia;
  2. Expor muitos dados para tornar a realidade incompreensível;
  3. Usar formas gráficas inapropriadas (distorcer os dados).

Introdução à visualização de dados

Melhores práticas em visualização de dados

- Retirar poluição para melhorar a visualização
- Dark Horse Analytics: menos é mais

Introdução à visualização de dados

Melhores práticas em visualização de dados

1. Remover coloração de fundo

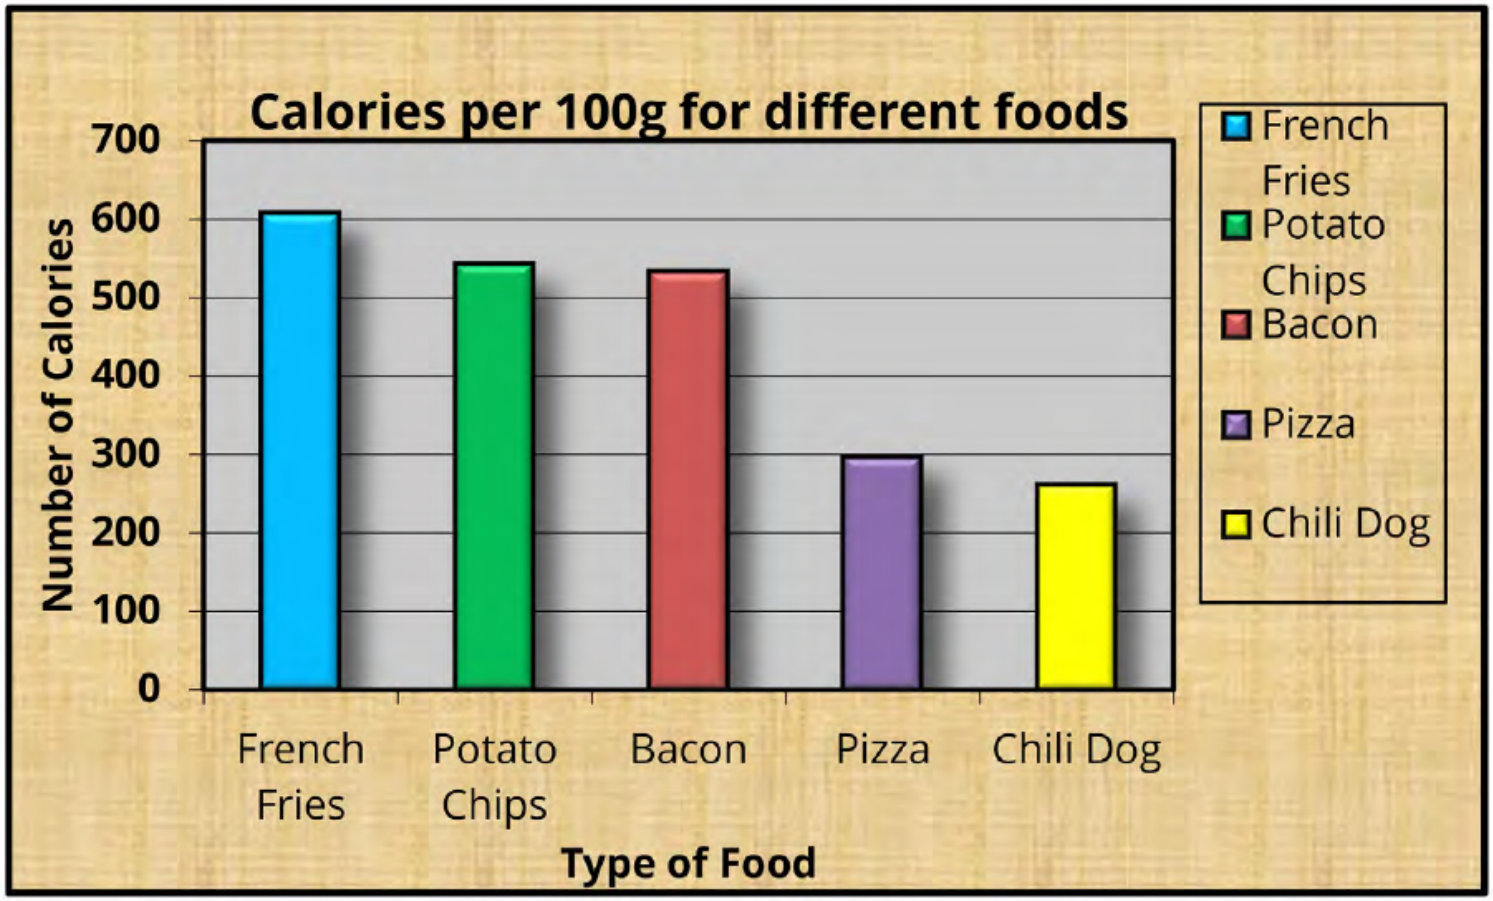

Introdução à visualização de dados

Melhores práticas em visualização de dados

2. Remover redundâncias

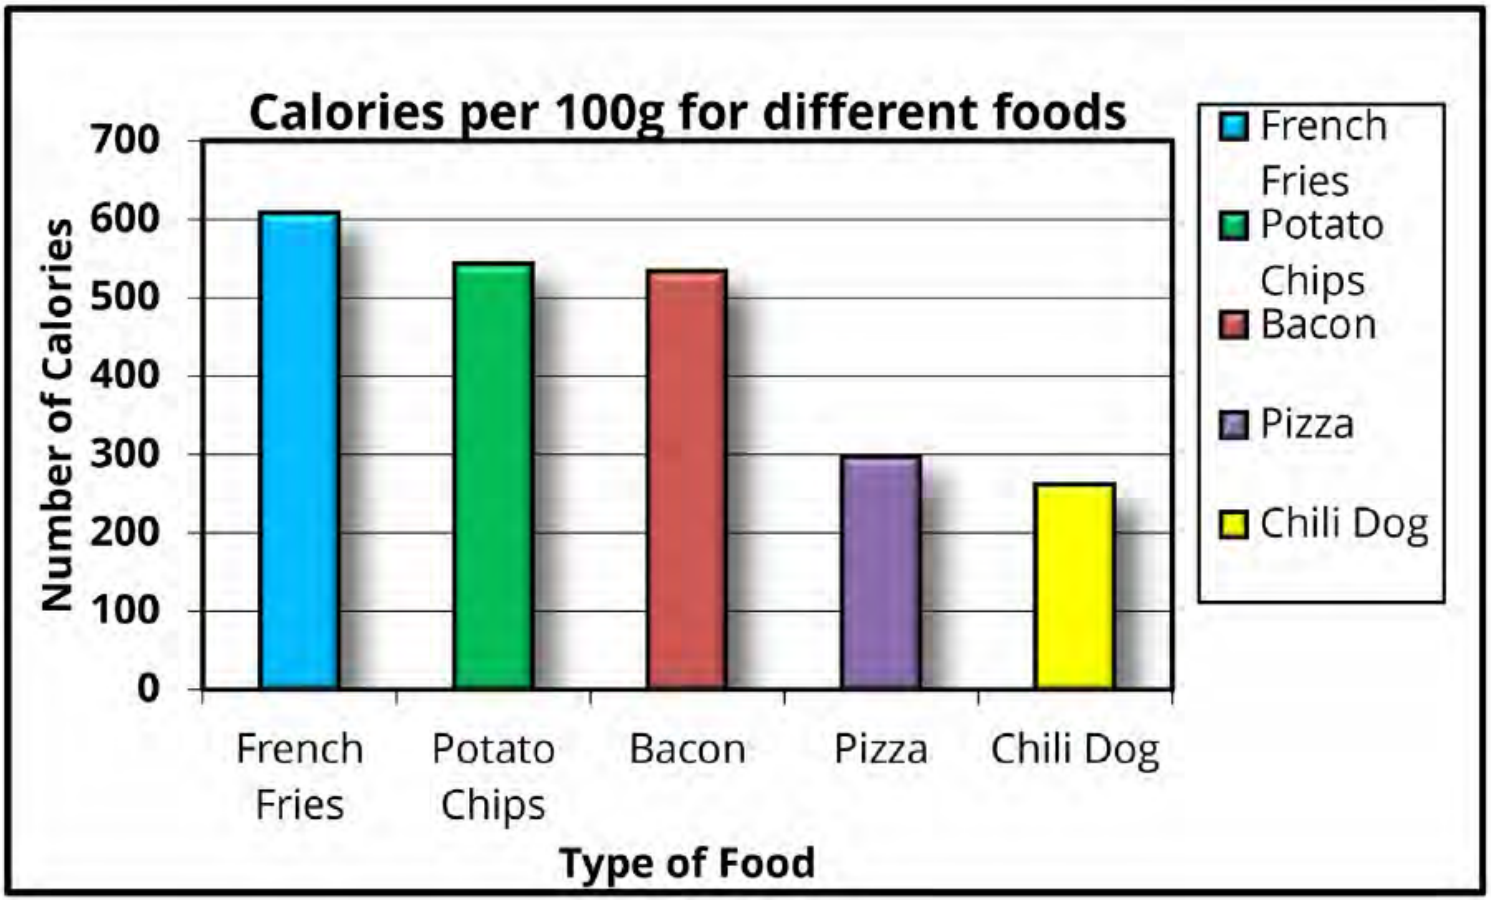

Introdução à visualização de dados

Melhores práticas em visualização de dados

3. Remover bordas

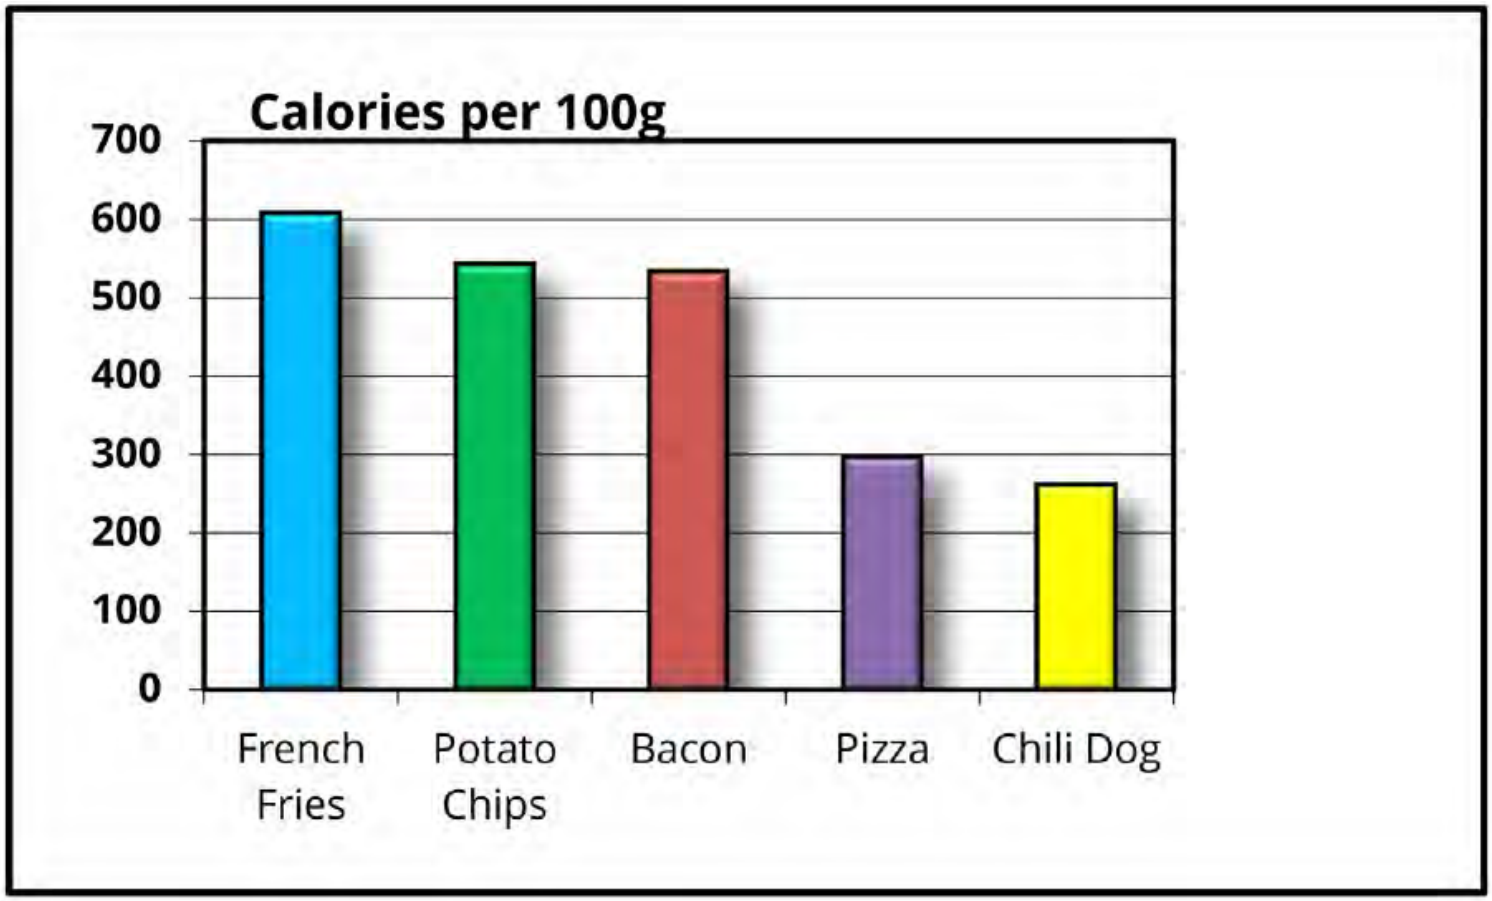

Introdução à visualização de dados

Melhores práticas em visualização de dados

4. Reduzir o número de cores

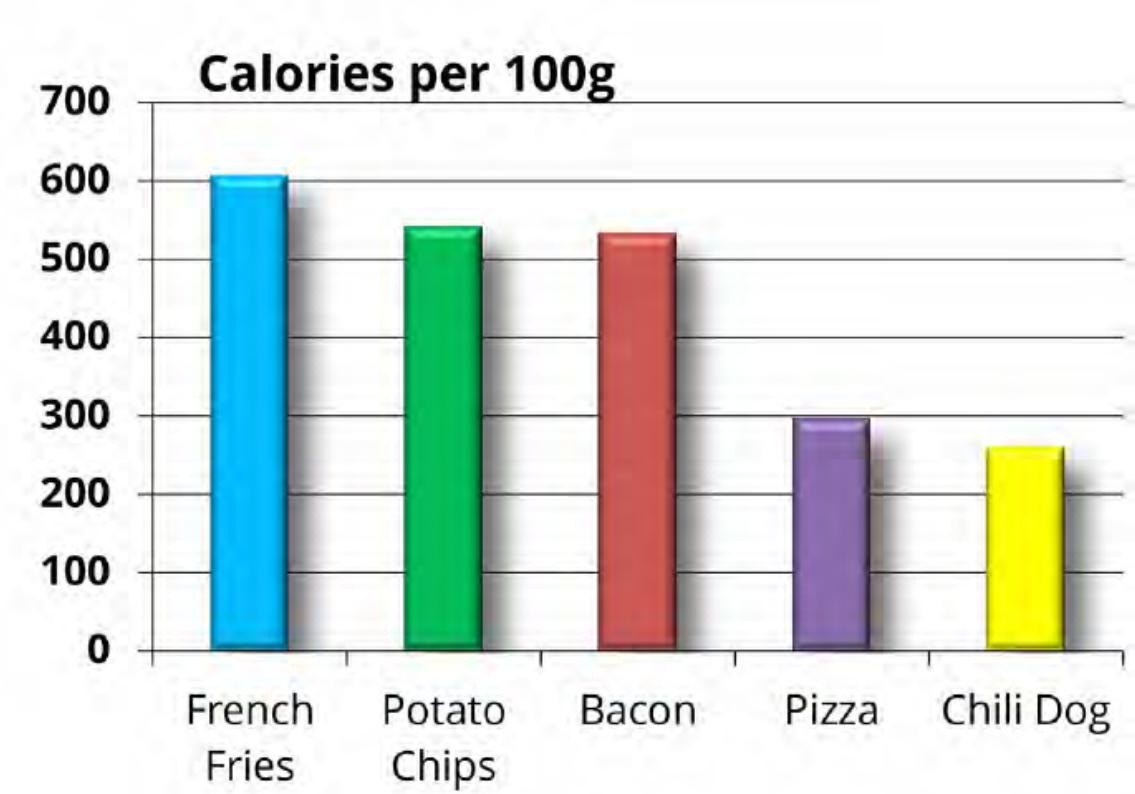

Introdução à visualização de dados

Melhores práticas em visualização de dados

5. Remover efeitos especiais

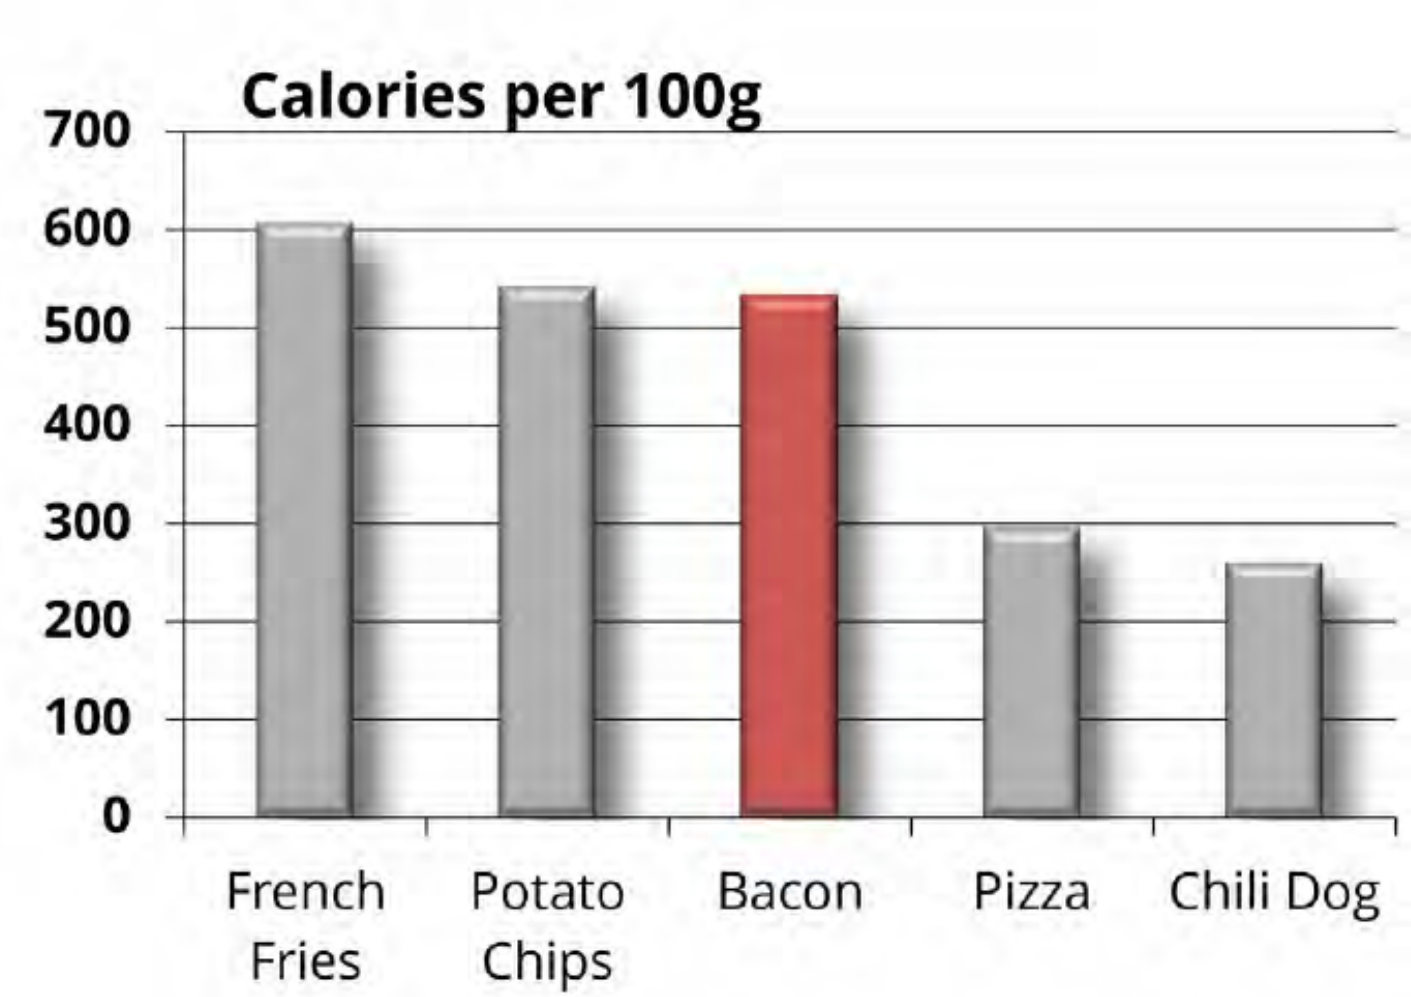

Introdução à visualização de dados

Melhores práticas em visualização de dados

6. Tornar rótulos mais leves

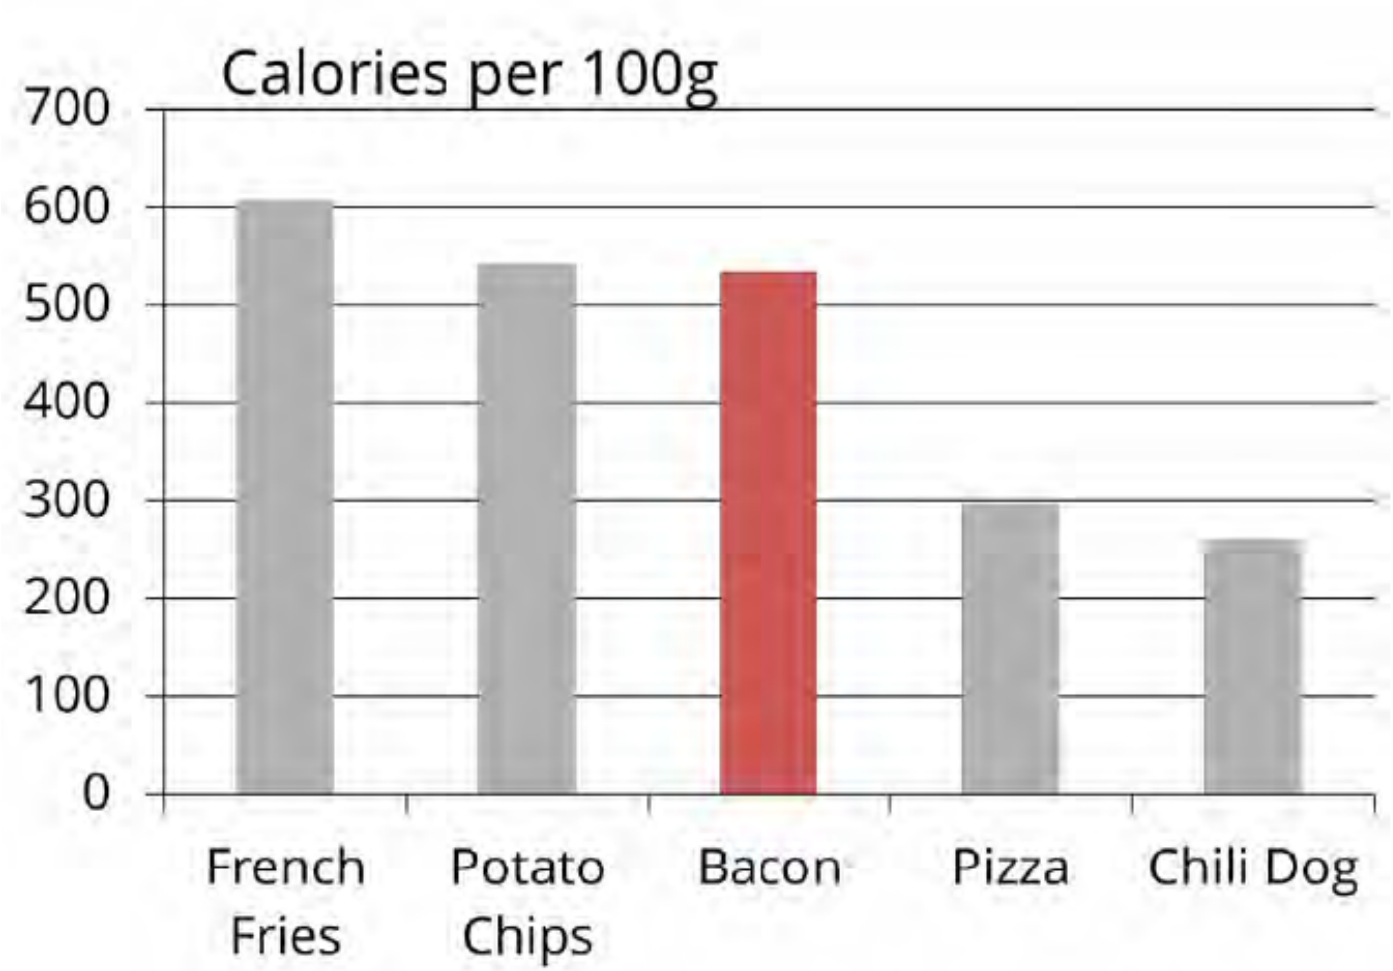

Introdução à visualização de dados

Melhores práticas em visualização de dados

7. Rotular diretamente (sem eixos)

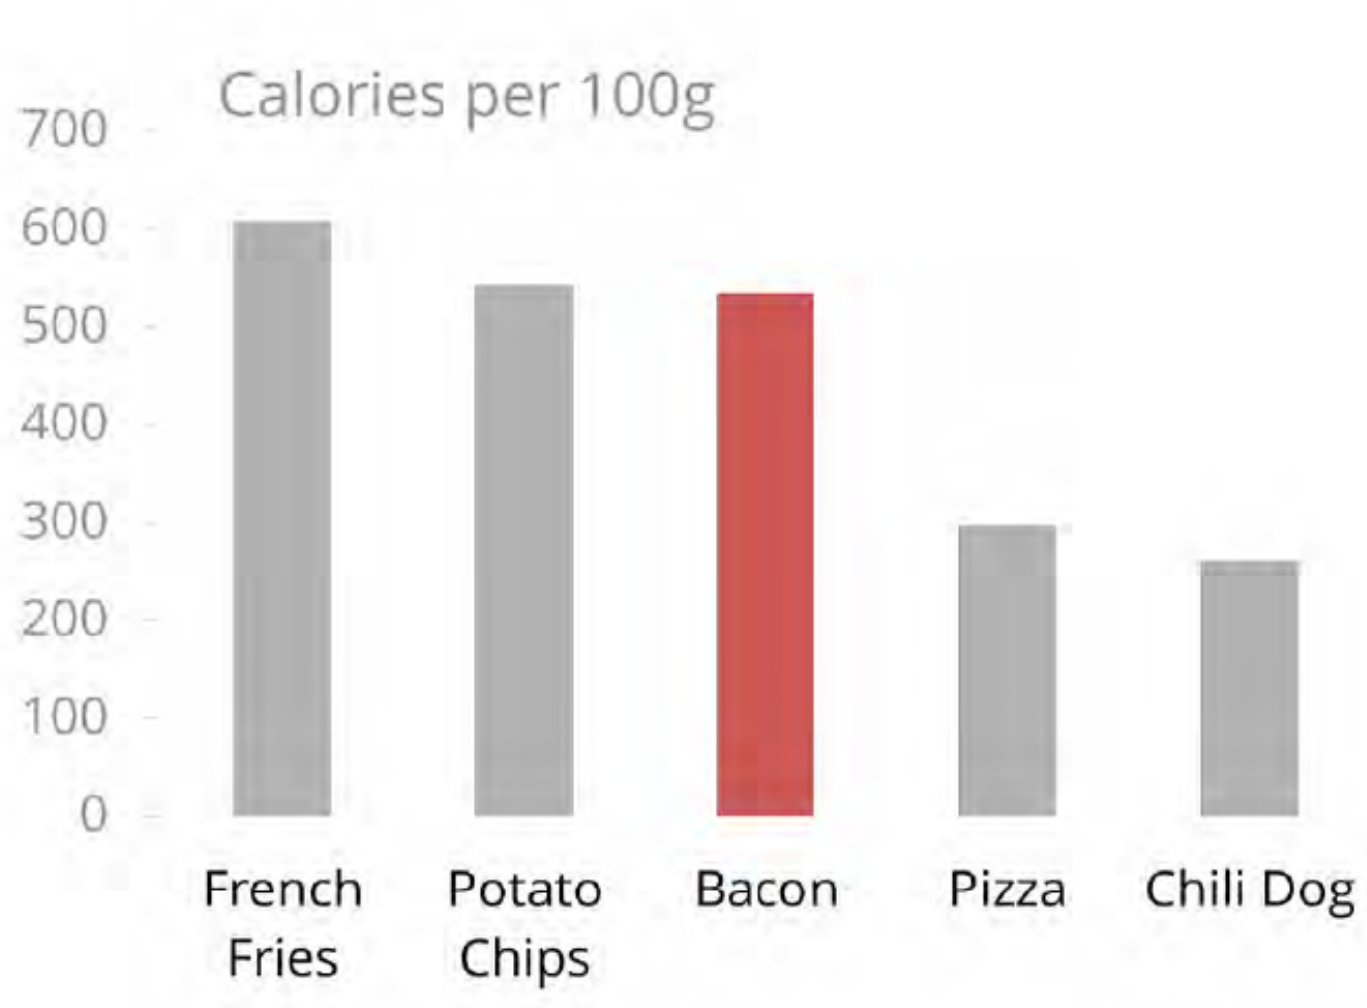

Introdução à visualização de dados

Melhores práticas em visualização de dados

8. Final

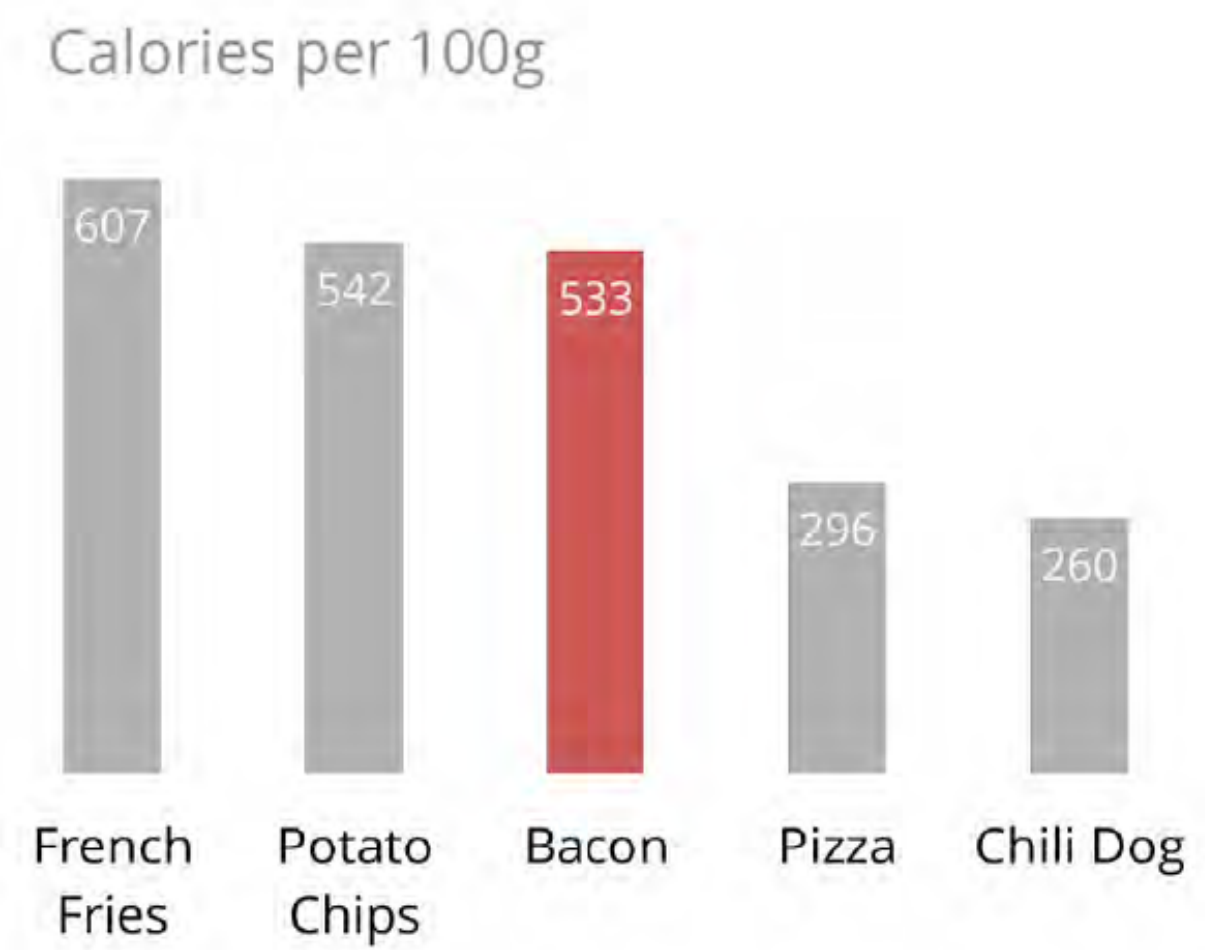

Introdução à visualização de dados

Melhores práticas em visualização de dados

9. Comparação

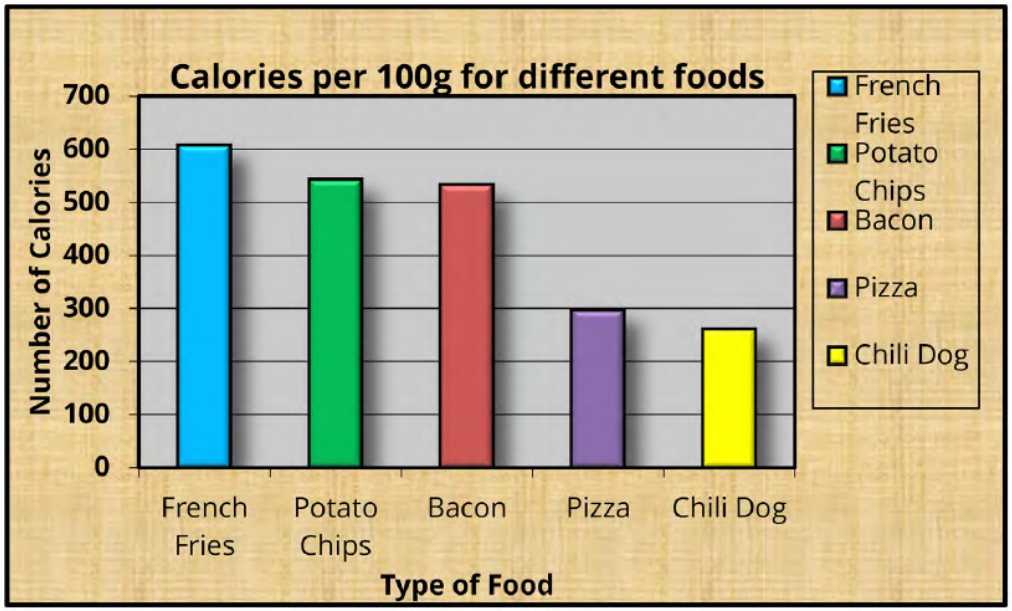

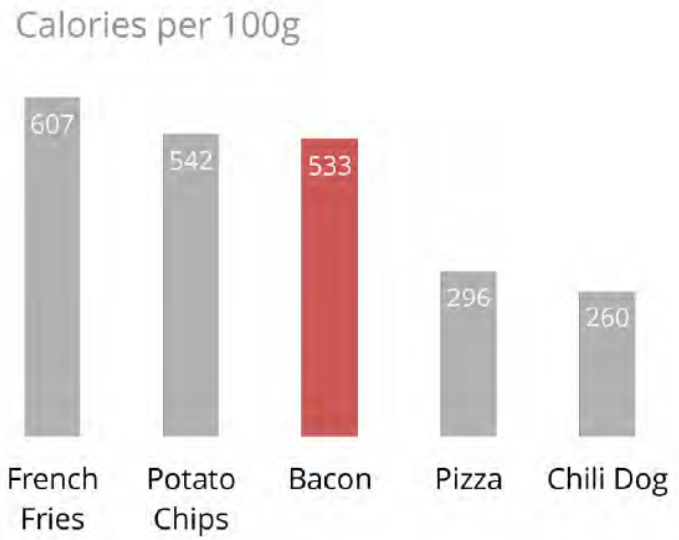

Sumário

Formas gráficas comuns para representação de dados

Barras, linhas e colunas

Barras/colunas simples

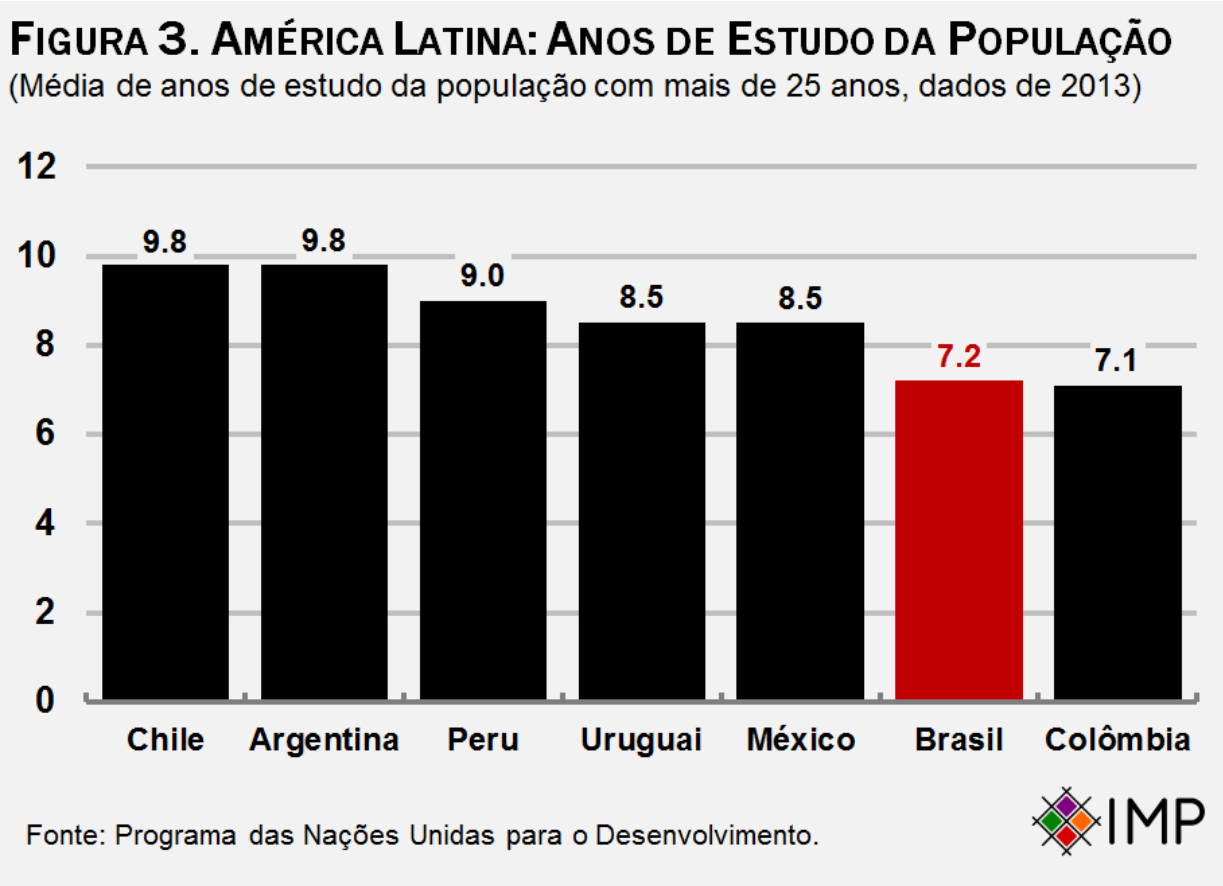

Formas gráficas comuns para representação de dados

Barras, linhas e colunas

Barras/colunas múltiplas

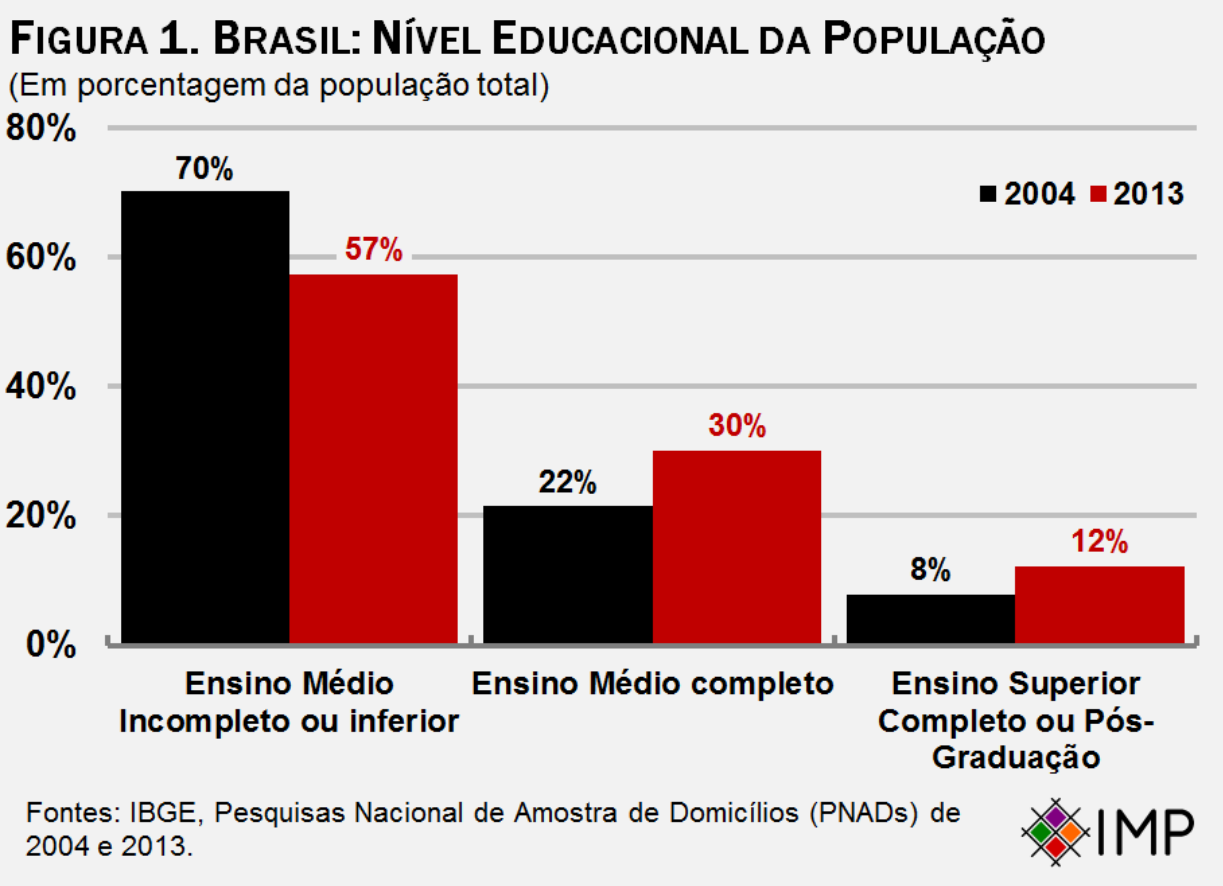

Formas gráficas comuns para representação de dados

Barras, linhas e colunas

Quando há muita informação: linhas (Imagine esse mesmo gráfico com barras múltiplas)

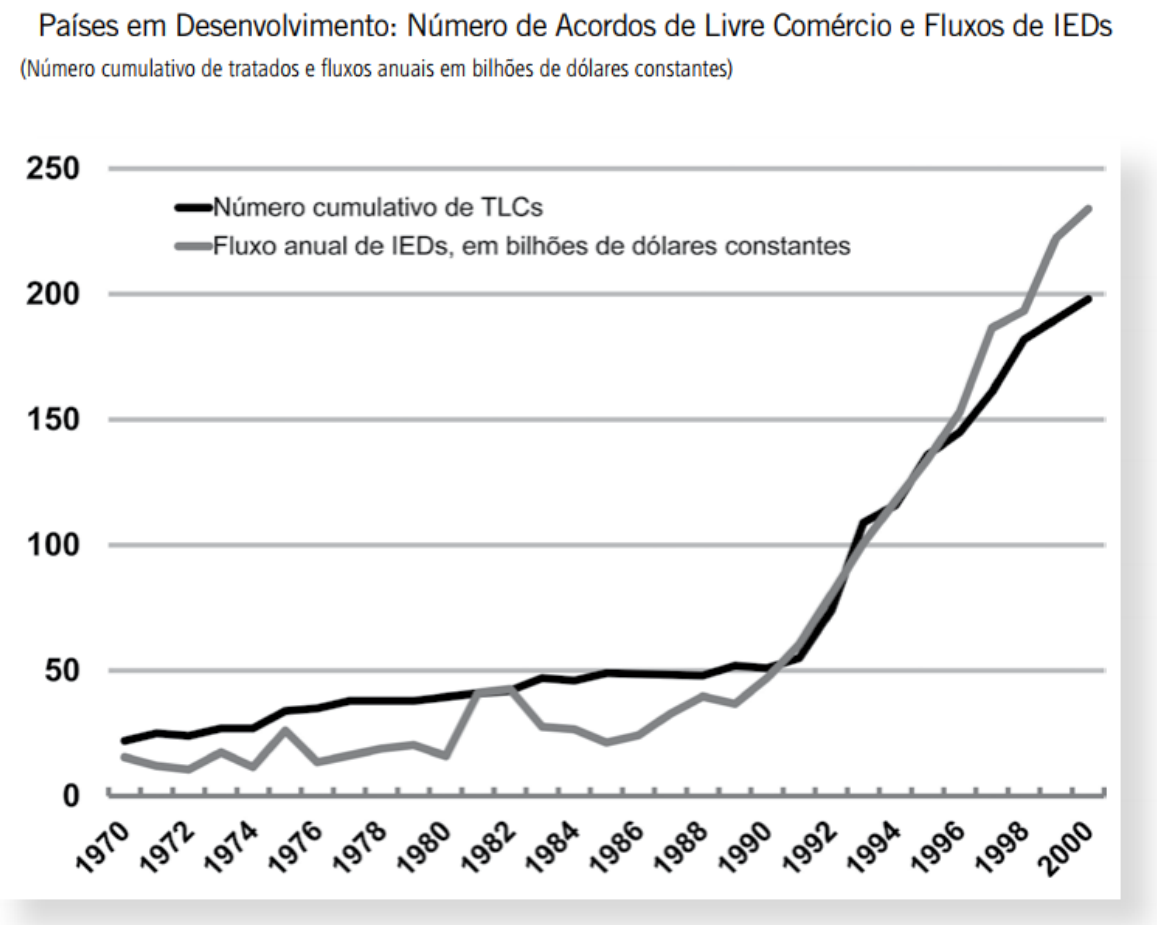

Formas gráficas comuns para representação de dados

Barras, linhas e colunas

Barras empilhadas

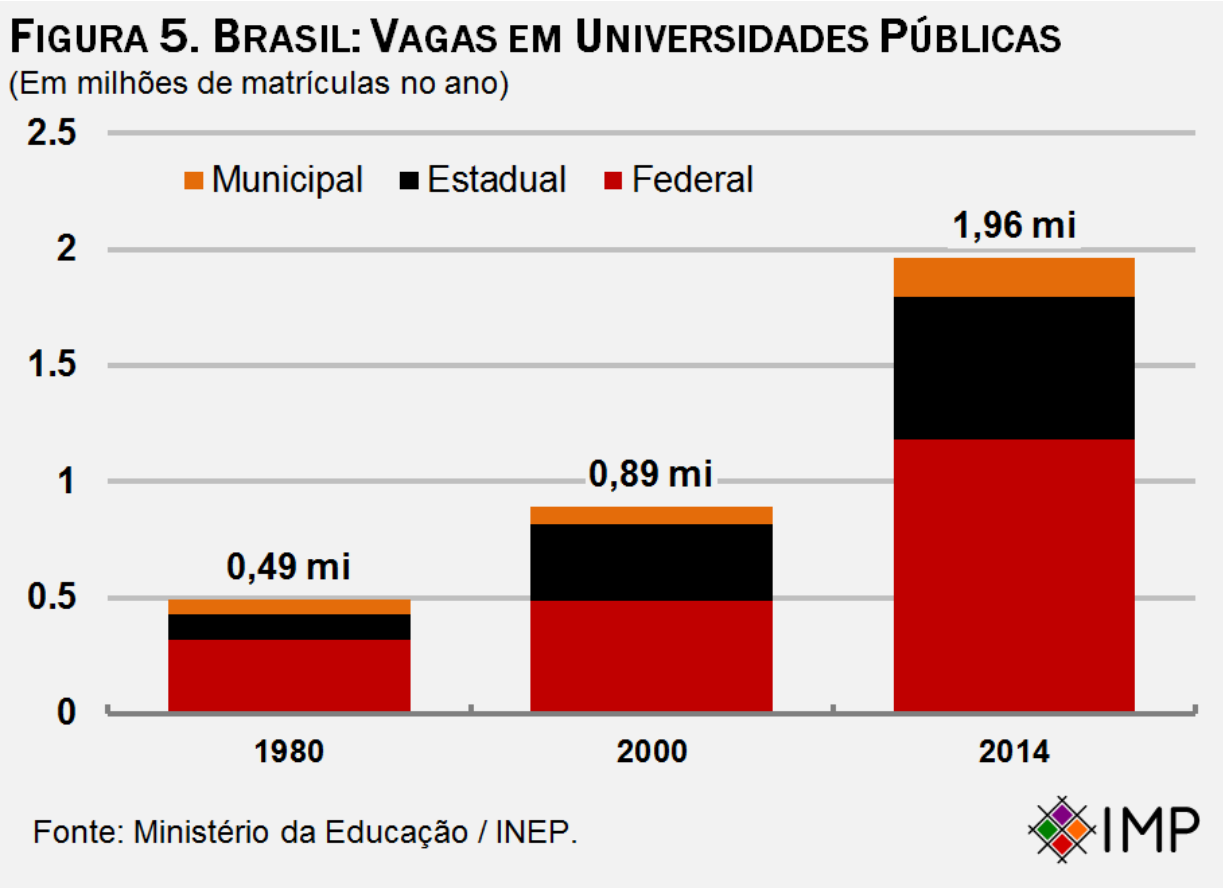

Formas gráficas comuns para representação de dados

Pizza e área

Gráfico de pizza (relativo a 100%)

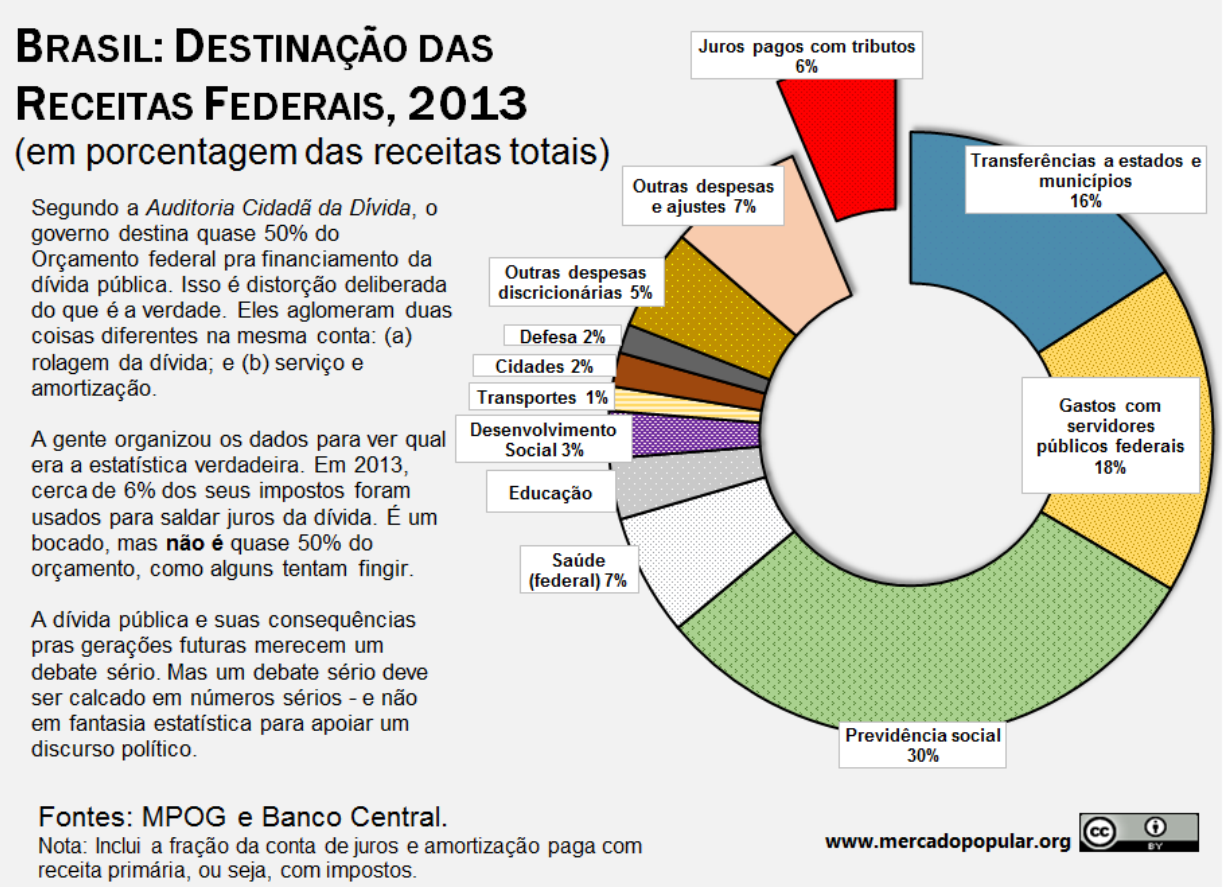

Formas gráficas comuns para representação de dados

Pizza e área

Gráfico de área (relativo a 100%)

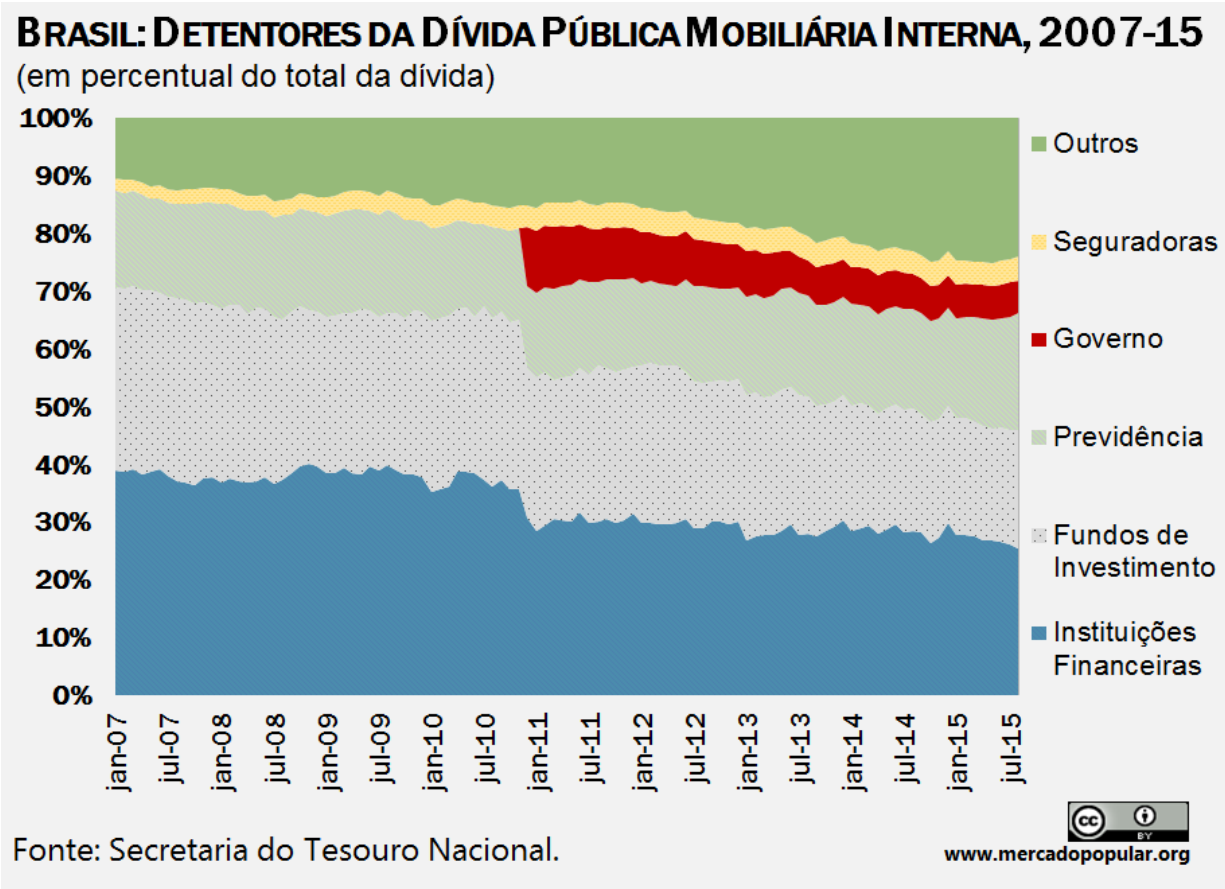

Formas gráficas comuns para representação de dados

Intervalo interquartil, boxplot e histograma

Linhas com intervalo interquartil

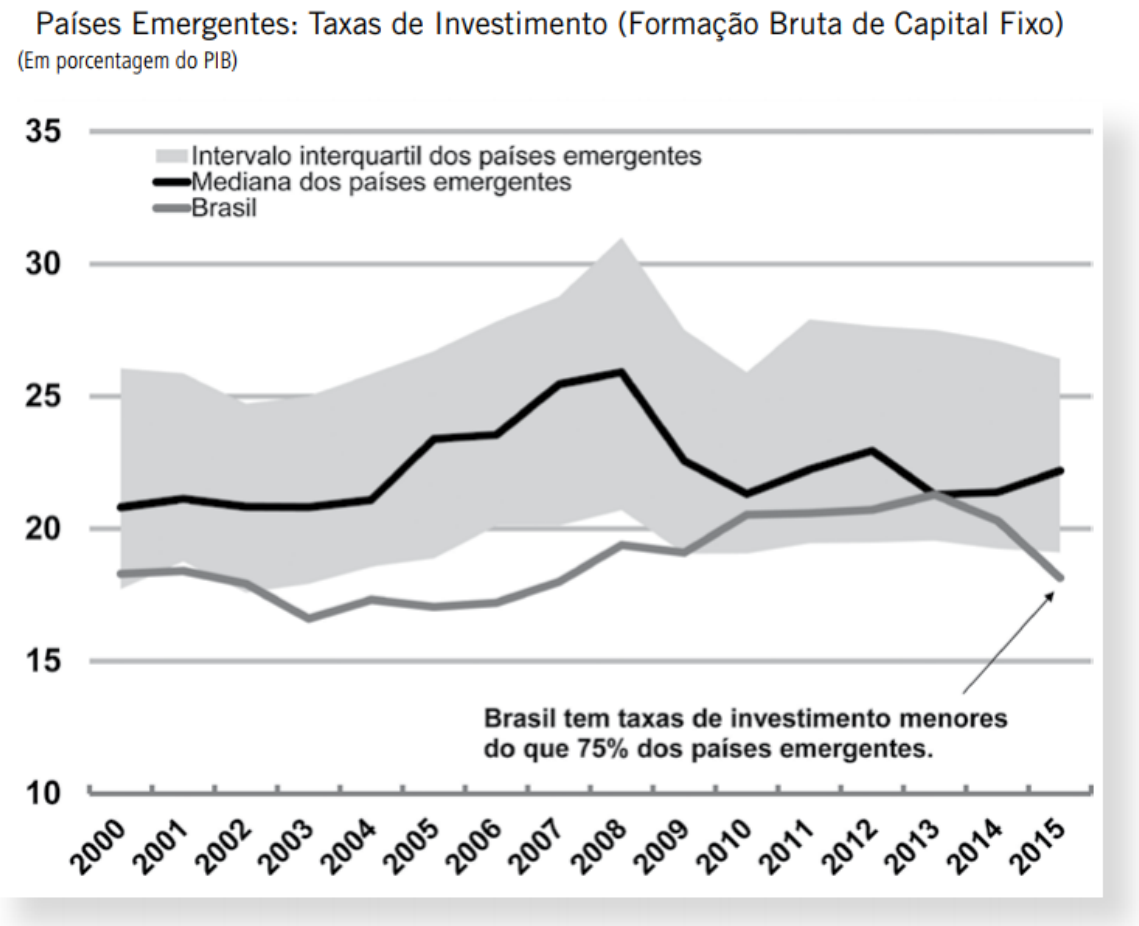

Fonte: Cálculos do autor dos dados de Haver Analytics e World Economic Outlook/ FMI. Inclui 53 países considerados como mercados emergentes pelo FMI.

Formas gráficas comuns para representação de dados

Intervalo interquartil, boxplot e histograma

Boxplot (Ex 1)

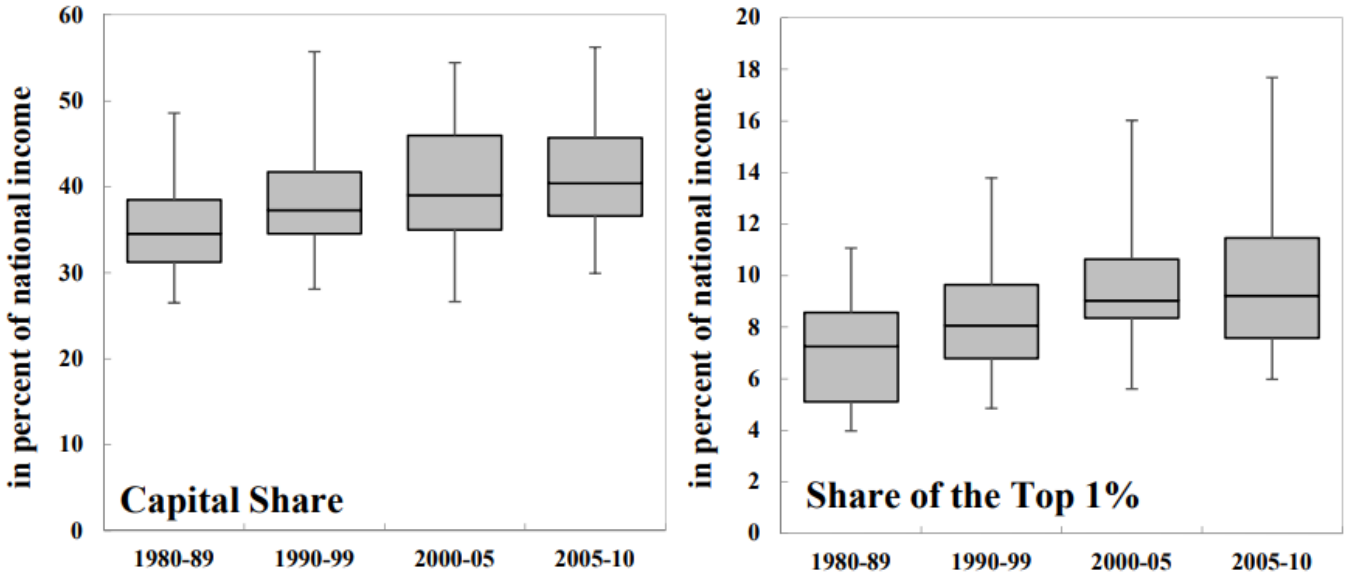

Figure 1: **Distribution of capital share and share of the top 1% over time.** Y-axis in percent, x-axis represents period averages. The sample refers to an unbalanced panel of 19 advanced economies ranging from 1981-2010. Boxplots show interquartile ranges and medians. Whiskers show minimums and maximums.

Formas gráficas comuns para representação de dados

Intervalo interquartil, boxplot e histograma

Boxplot (Ex 2)

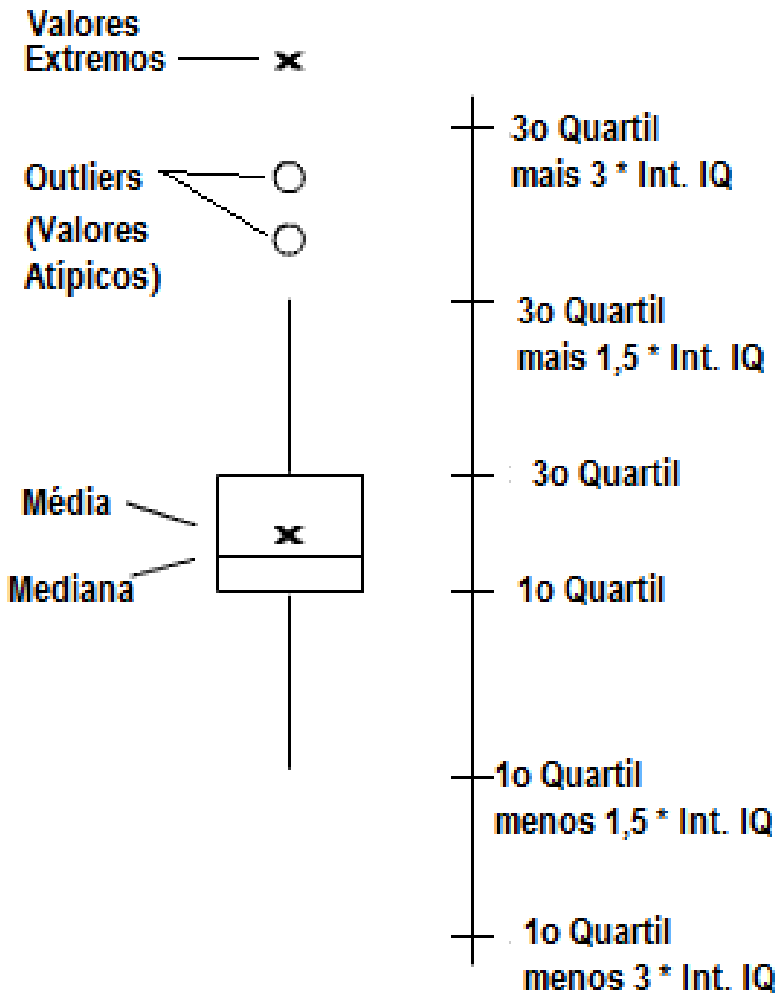

Formas gráficas comuns para representação de dados

Intervalo interquartil e boxplot

Histograma

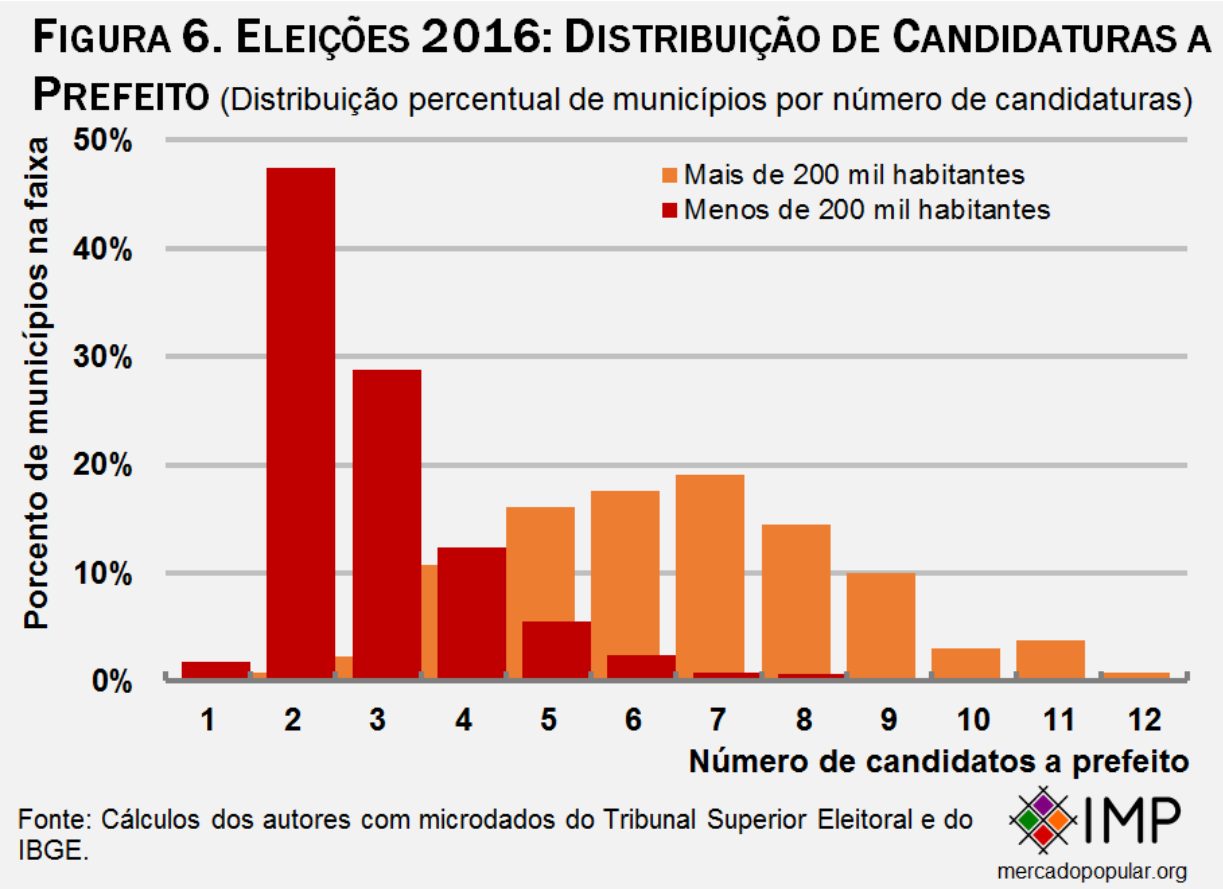

Formas gráficas comuns para representação de dados

Diagrama de dispersão

Diagrama de dispersão (scatterplot)

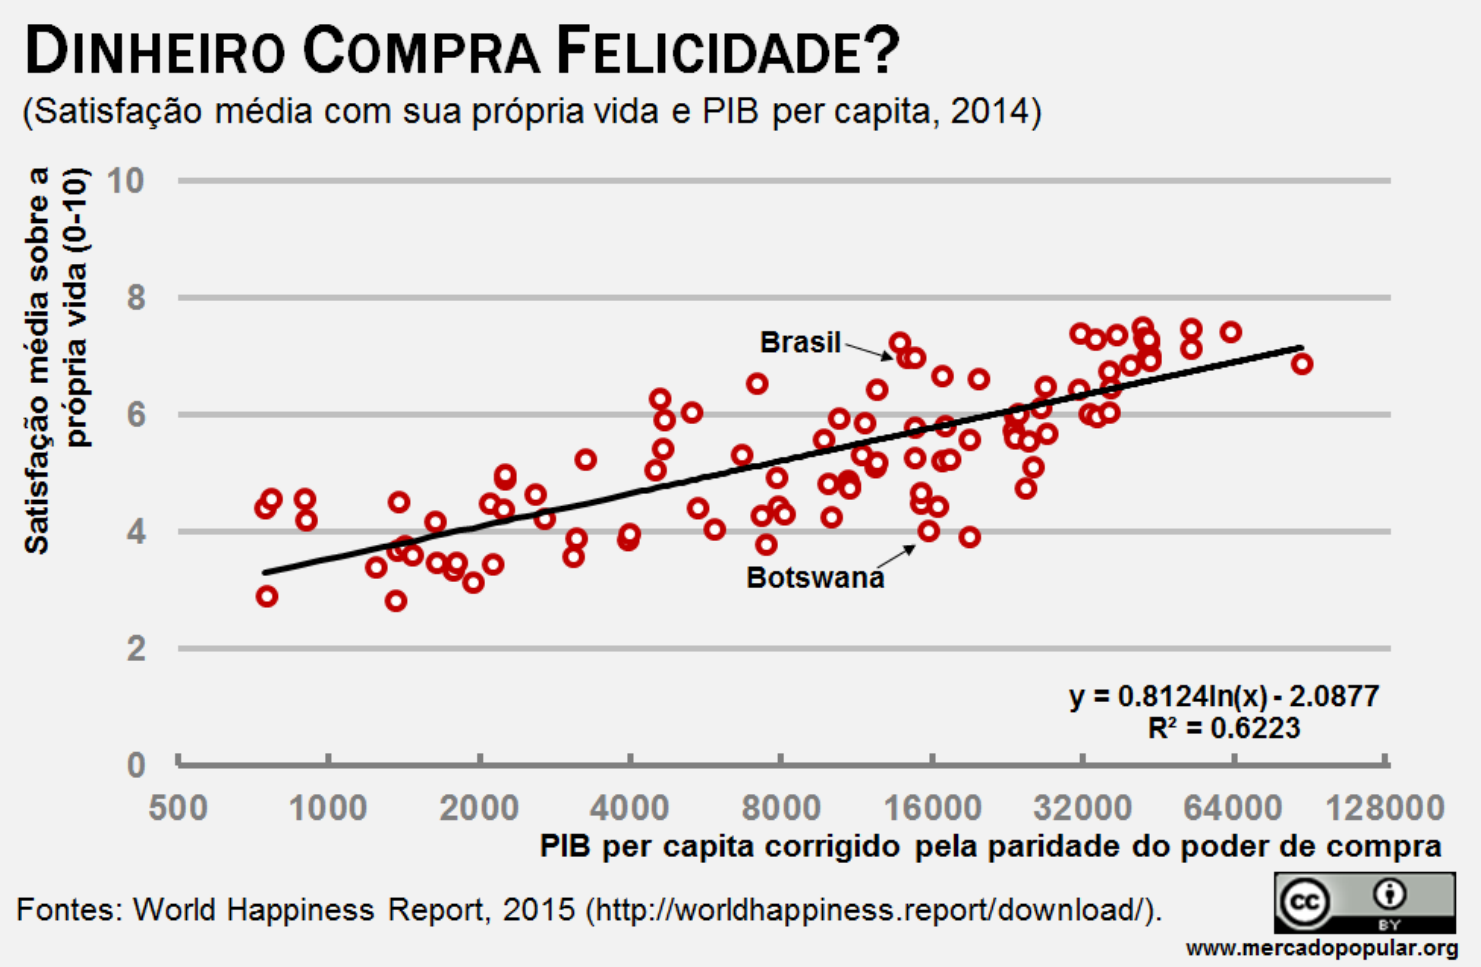

Sumário

Introdução às ferramentas gráficas em Python

Introdução ao `matplotlib` e `seaborn`

- `matplotlib` e `seaborn` são duas das principais ferramentas em Python!
- Para quem usa R, há também uma versão de `ggplot2`, com a mesma sintaxe (grammar of graphics), em Python!
- A primeira coisa a fazer é importar essas duas ferramentas:

```
import matplotlib.pyplot as plt
import seaborn as sns
```

Introdução às ferramentas gráficas em Python

Introdução ao `matplotlib` e `seaborn`

- A ideia fundamental do `matplotlib`: código é rápido, gráficos são demorados.
- Por isso, a forma como ele funciona é que primeiro definimos todas as características do gráfico e somente depois pedimos para máquina criá-la:

```
x = [1,2,3,4]
y = [5,6,7,8]
plt.plot(x, y)
plt.xlabel('x')
plt.ylabel('y')
plt.title('Amostra')
plt.show()
```

Introdução às ferramentas gráficas em Python

Introdução ao `matplotlib` e `seaborn`

Desenho da máquina

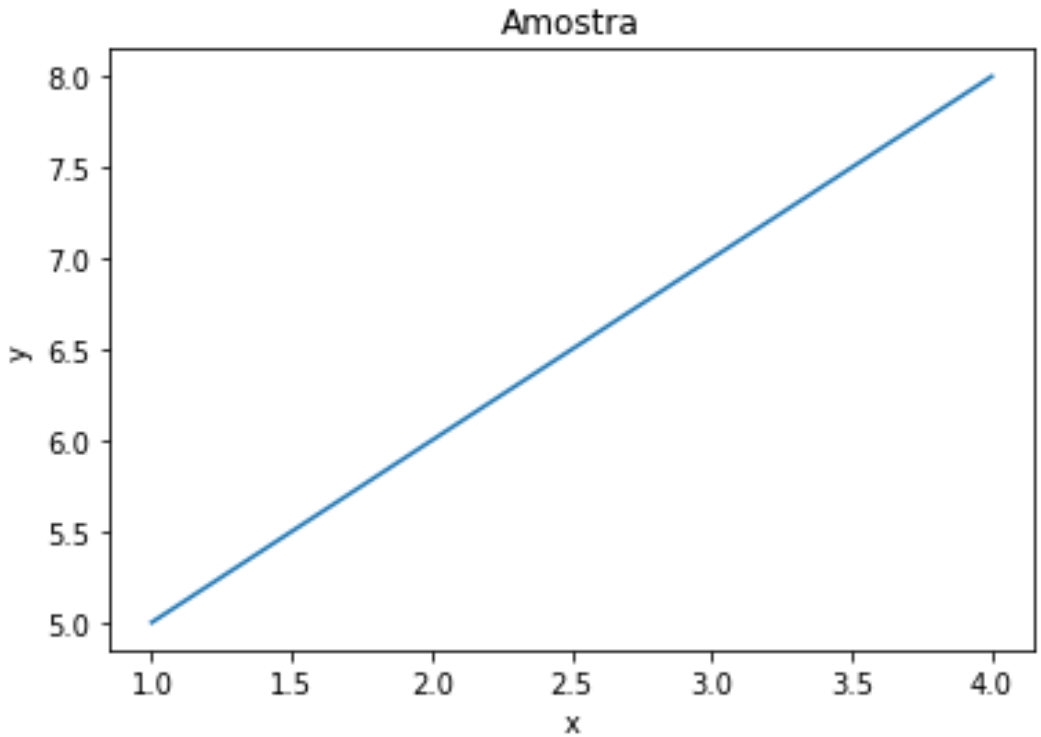

Exemplos de gráficos

Linha

- Vamos construir um gráfico com duas linhas no `matplotlib`.
- Primeiro, precisamos criar nossos dados.

```
import numpy as np
anos = np.linspace(2001,2010,10)
y1 = [1,2,3,4,5,6,7,8,9,10]
y2 = [i+10 for i in y1]
```

Exemplos de gráficos

Linha

- Depois, adicionamos as linhas:

```
plt.plot(anos, y1, label="y1", color="red")
plt.plot(anos, y2, label="y2", color="black")
```

- Os rotulos:

```
plt.legend(loc="upper left")
plt.ylabel("Valores")
plt.xlabel("Anos")
plt.title("Duas linhas")
```

- E plotamos:

```
plt.show()
```

Exemplos de gráficos

Linha

Desenho da máquina:

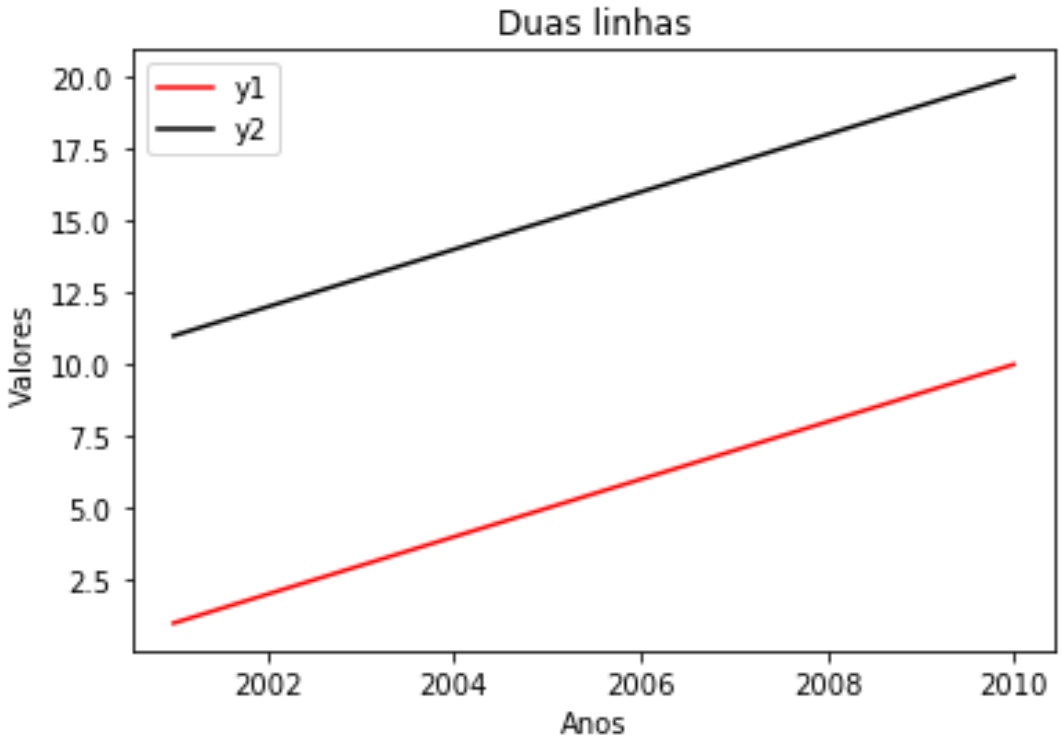

Exemplos de gráficos

Linha

- Vamos fazer a mesma coisa no seaborn `matplotlib`.
- Primeiro, precisamos levar nossos dados para um `pandas DataFrame`.

```
import pandas as pd
data = {'y1': y1, 'y2': y2}
df = pd.DataFrame(data, index=anos)
df = df.unstack().reset_index()
df.columns = ['variavel', 'data', 'valor']
```

- Depois, conseguimos plotar em uma linha:

```
sns.tsplot(df, time='data', unit='variavel',
condition='variavel', value='valor')
```

Exemplos de gráficos

Linha

Desenho da máquina:

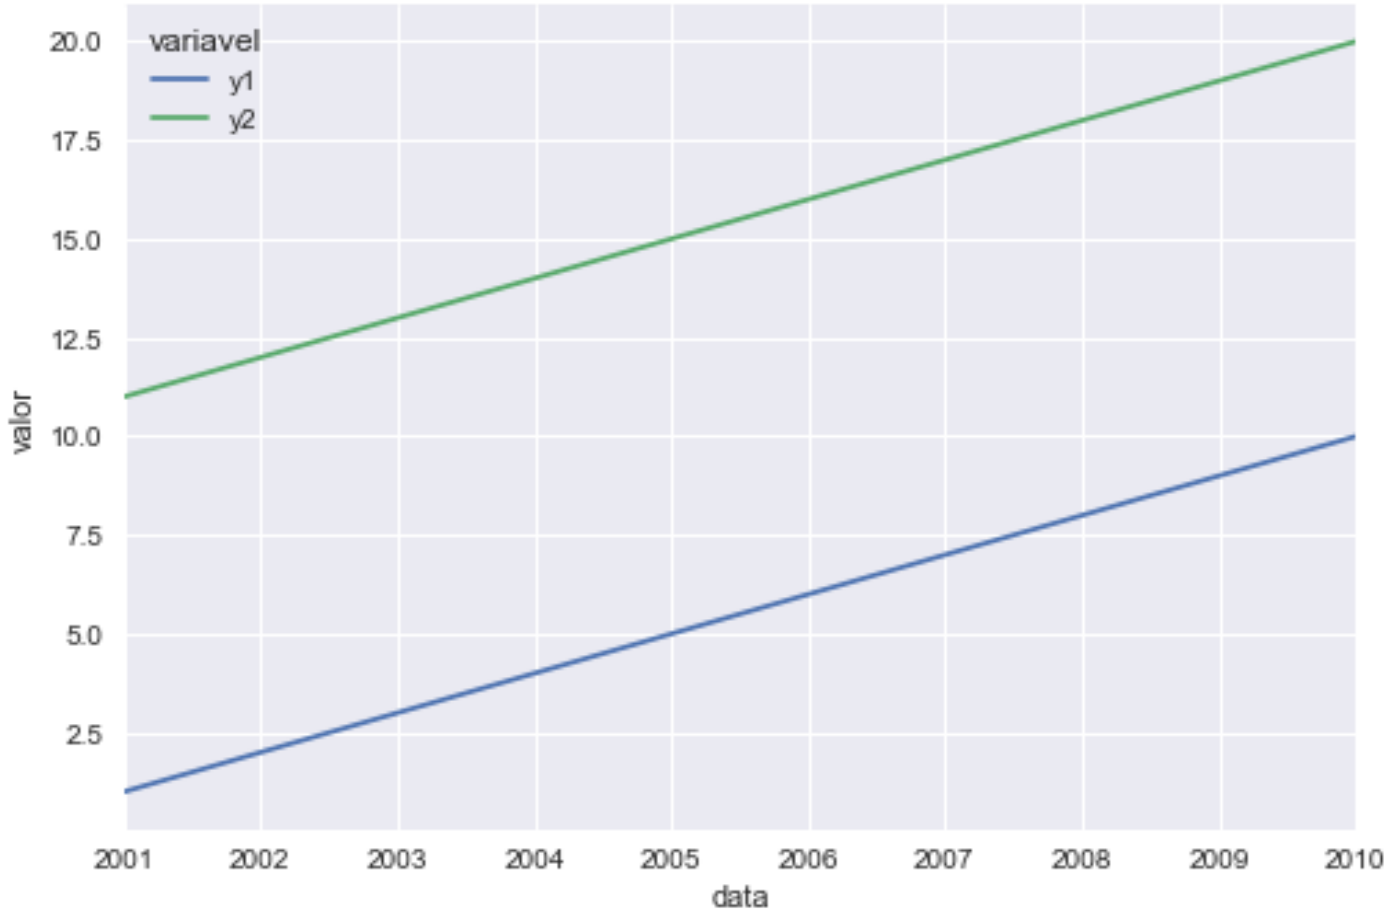

Exemplos de gráficos

Pizza

- Carregamos nossos dados.

```
rotulos = ['Feijão', 'Arroz', 'Carne',
'Farofa', 'Batata Frita', 'Outros']
respostas = [200, 300, 100,
150, 200, 100]
```

- Depois, criamos o grafico:

```
plt.pie(respostas, labels=rotulos,
autopct='%1.1f%%')
plt.title('O que está no almoço brasileiro?')
plt.show()
```

Exemplos de gráficos

Pizza

Desenho da máquina:

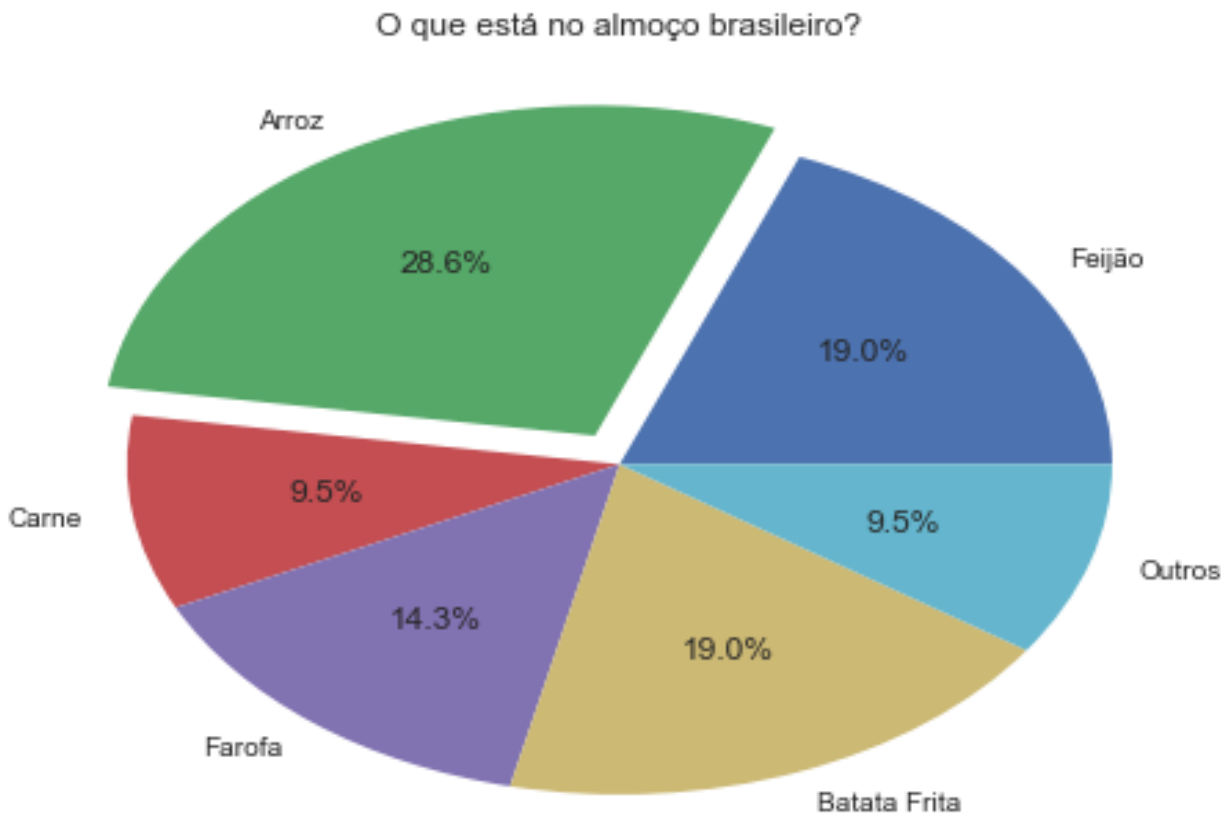

Exemplos de gráficos

Barras

- Carregamos nossos dados.

```
rotulos = ['Feijão', 'Arroz', 'Carne',
'Farofa', 'Batata Frita', 'Outros']
respostas = [200, 300, 100,
150, 200, 100]
```

- Depois, criamos o gráfico:

```
sns.barplot(rotulos, respostas).
set_title('Almoço do Brasileiro: Número de Respostas')
```

Exemplos de gráficos

Barra

Desenho da máquina:

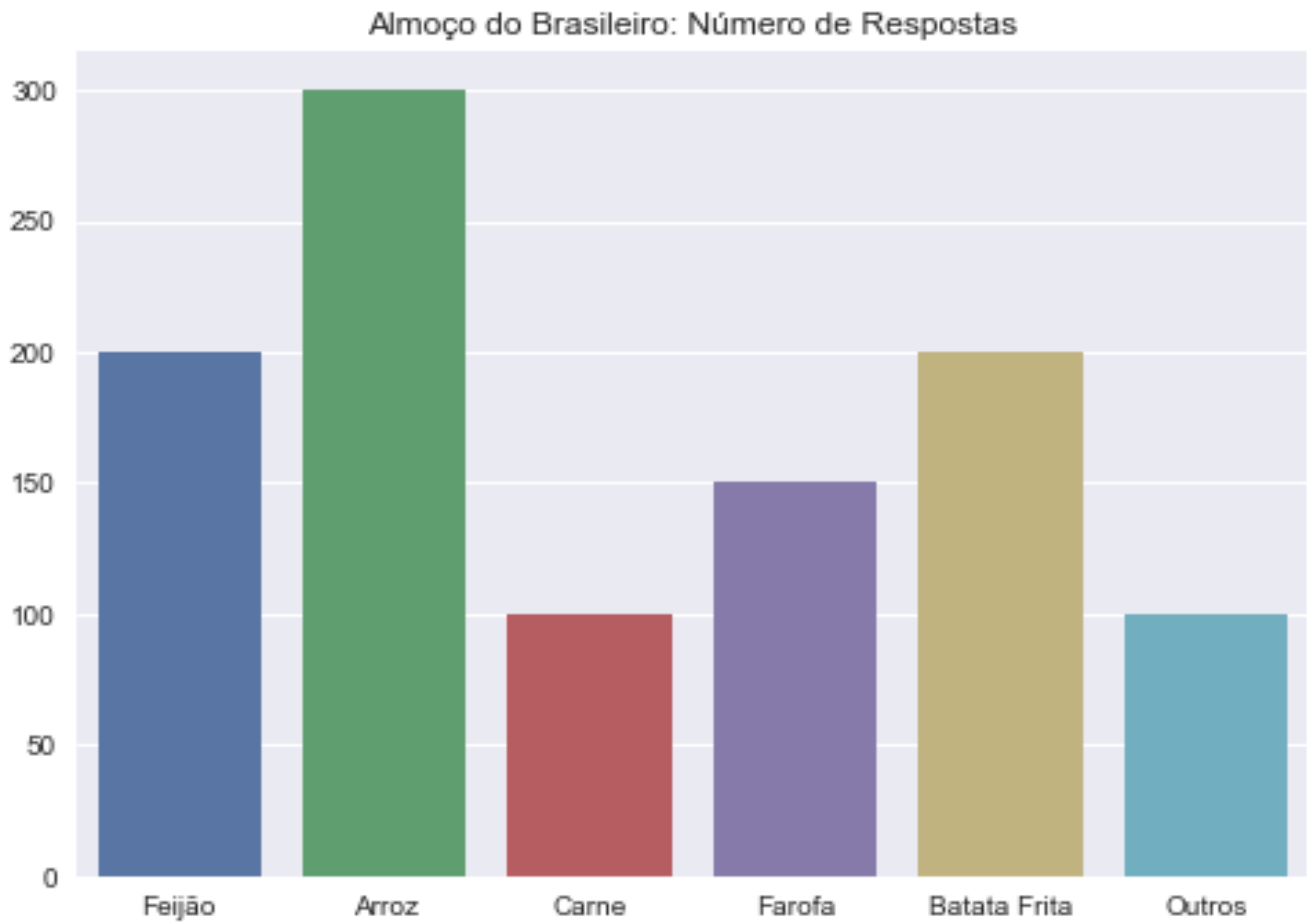

Exemplos de gráficos

Boxplot

- Carregamos nossos dados.

```
url = "https://raw.githubusercontent.com/ \
omercadopopular/cgoes/ \
master/piketty/fdatabasetax.csv"
```

- Depois, criamos o gráfico:

```
plt.xticks(rotation=45)
plt.title('Países Avançados: Fração da Renda Nacional
apropriada pelo 1% mais rico')
sns.boxplot(x='year', y='top1', data=piketty)
```

Exemplos de gráficos

Barra

Desenho da máquina: